TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG

BÁO CÁO PROJECT

# Auditing Bias in Credit Scoring


| **Sinh viên thực hiện** | **Mã số sinh viên** |
|---|---|
| Lương Trung Kiên | 20250386E |
| Lê Anh Thiên | 20250462E |
| Đoàn Thanh Tuấn | 20241631E |
| Lưu Đăng Tuấn | 20241630E |

| | |
|---|---|
| Giảng viên hướng dẫn | *TS. Nguyễn Đức Anh* |
| Ngành | *KSCS GEN AI* |


Hà Nội, Ngày 21 tháng 6 năm 2026

# Tóm tắt

Project nghiên cứu bài toán công bằng trong chấm điểm tín dụng trên bộ dữ liệu Statlog German Credit, gồm 1.000 hồ sơ vay và nhãn nhị phân cho biết hồ sơ có rủi ro tốt hay xấu. Trọng tâm của bài toán là kiểm tra ảnh hưởng của thuộc tính nhạy cảm gender, trong đó male được xem là nhóm ưu thế và female là nhóm kém ưu thế. Các thí nghiệm có gender được tách riêng nhằm tạo điểm so sánh ban đầu.

Quy trình thực nghiệm đi theo ba bước. Thứ nhất, các mô hình Logistic Regression, XGBoost và CatBoost được huấn luyện với gender như một feature để đánh giá mức lệch khi mô hình có quyền truy cập trực tiếp vào biến nhạy cảm. Thứ hai, gender được loại khỏi feature matrix để tạo baseline không dùng biến nhạy cảm. Thứ ba, hai kỹ thuật giảm thiên lệch là Reweighing và Reject Option Classification được áp dụng trên các baseline không có gender. Mỗi cấu hình được đánh giá bằng 5-fold cross-validation, với hiệu năng đo bằng AUC và Balanced Accuracy, còn fairness đo bằng Statistical Parity Difference (SPD) và Average Odds Difference (AOD).

Kết quả cho thấy việc chỉ loại bỏ gender giúp giảm chênh lệch giữa hai nhóm nhưng không loại bỏ hoàn toàn bất công, vì các biến còn lại vẫn có thể đóng vai trò proxy cho gender. Phân tích SHAP trên các mô hình phụ dự đoán gender xác nhận tín hiệu proxy còn tồn tại trong các thuộc tính như `purpose`, `employment_since`, `checking_status`, `credit_amount` và `age`. Trong các phương pháp giảm thiên lệch, Reject Option Classification đạt cân bằng tốt nhất giữa hiệu năng và fairness. Hai mô hình được chọn cho kết luận cuối cùng là XGBoost + ROC, nhờ AUC và Balanced Accuracy cao nhất trong nhóm được xét, và Logistic Regression + ROC, nhờ AOD gần bằng 0 và khả năng diễn giải tốt.

# Mục lục

**Tóm tắt** **i**

**1 Giới thiệu** **1**

1.1 Bối cảnh . . . . . 1

1.2 Mục tiêu nghiên cứu . . . . . 1

1.3 Phạm vi và giả định . . . . . 2

1.4 Đóng góp của project . . . . . 2

**2 Tổng quan nghiên cứu liên quan** **3**

2.1 Credit scoring truyền thống và học máy . . . . . 3

2.2 Fairness trong học máy . . . . . 3

2.3 Các hướng giảm thiên lệch . . . . . 4

2.4 Explainability và proxy discrimination . . . . . 4

2.5 Vị trí của project trong các hướng nghiên cứu . . . . . 5

**3 Cơ sở lý thuyết** **6**

3.1 Credit scoring như một bài toán phân loại nhị phân . . . . . 6

3.2 Fairness theo nhóm . . . . . 6

3.3 Reweighing . . . . . 7

3.4 Reject Option Classification . . . . . 7

3.5 SHAP và phân tích proxy . . . . . 8

**4 Dữ liệu và tiền xử lý** **9**

4.1 Bộ dữ liệu German Credit . . . . . 9

4.2 Phân phối nhãn và gender . . . . . 9

4.3 Các thuộc tính sau khi loại bỏ personal status . . . . . 10

4.4 Cross-validation và tránh data leakage . . . 10
4.5 Các tập dữ liệu phục vụ thí nghiệm . . . 11

**5 Phương pháp 13**
5.1 Reweighing (RW) . . . 13
5.2 Reject Option Classification (ROC) . . . 14

**6 Thiết kế thực nghiệm 16**
6.1 Danh sách cấu hình . . . 16
6.2 Protocol đánh giá . . . 16
6.3 Các metric . . . 17
6.4 Kiểm soát độ ổn định giữa các fold . . . 17

**7 Kết quả thực nghiệm 18**
7.1 Tổng quan hiệu năng và fairness . . . 18
7.2 Phân tích từng phương pháp cải thiện công bằng . . . 19
7.2.1 Loại bỏ Gender . . . 19
7.2.2 Reweighing (RW) . . . 19
7.2.3 Reject Option Classification (ROC) . . . 20
7.3 Trade-off giữa AUC và AOD . . . 20
7.4 Approval gap theo gender . . . 21
7.5 Bảng phụ theo nhóm . . . 22
7.6 Hai mô hình được chọn . . . 24

**8 Phân tích proxy của gender bằng SHAP 25**
8.1 Động cơ . . . 25
8.2 Proxy analysis với Logistic Regression . . . 25
8.3 Proxy analysis với XGBoost . . . 27
8.4 SHAP của mô hình có gender . . . 29
8.5 Ý nghĩa đối với lựa chọn mô hình . . . 30

**9 Kết luận và hướng phát triển 31**
9.1 Kết luận chính . . . 31
9.2 Khuyến nghị sử dụng . . . 32

9.3 Hạn chế . . . . . 32
9.4 Hướng phát triển . . . . . 32

# Danh sách bảng


4.1 Phân phối nhãn và gender trong bộ dữ liệu sau xử lý. . . . . 10

4.2 Các biến còn lại sau khi loại bỏ personal status. . . . . 11

7.1 Hiệu năng và fairness theo 5-fold cross-validation trên 12 cấu hình được chọn cho báo cáo. . . . . 18

7.2 Thay đổi performance và fairness của từng phương pháp so với mốc tham chiếu. Remove gender so với model có gender; RW và ROC so với baseline không có gender. Giá trị giảm của |SPD|/|AOD| dương nghĩa là fairness được cải thiện. . . . . 19

7.3 Bảng phụ về approval rate, TPR, TNR và FPR theo gender trên 1.000 dự đoán out-of-fold. . . . . 23

7.4 So sánh chi tiết hai mô hình cuối cùng được chọn: Logistic Regression + ROC và XGBoost + ROC. . . . . 24

7.5 Metric theo từng fold của hai mô hình cuối cùng, dùng để kiểm tra độ ổn định giữa các lần chia dữ liệu. . . . . 24

8.1 Tám attribute có proxy-risk cao nhất theo model Logistic Regression dự đoán gender. . . . . 26

8.2 Tám attribute có proxy-risk cao nhất theo model XGBoost dự đoán gender. 28

# Danh sách hình vẽ


4.1 Phân phối good/bad credit theo gender. . . . . 10

7.1 Trade-off giữa AUC và trị tuyệt đối AOD của 12 cấu hình. . . . . 21
7.2 Khoảng cách approval rate theo gender trên OOF predictions. . . . . 21

8.1 Phân tích proxy bằng Logistic Regression. . . . . 26
8.2 SHAP beeswarm của mô hình phụ Logistic Regression dự đoán gender. . . 27
8.3 Phân tích proxy bằng XGBoost. . . . . 28
8.4 SHAP beeswarm của mô hình phụ XGBoost dự đoán gender. . . . . 29
8.5 SHAP summary bar của ba mô hình có gender. . . . . 30

# Chương 1

# Giới thiệu

## 1.1 Bối cảnh

Chấm điểm tín dụng là một trong những ứng dụng quan trọng của học máy trong tài chính. Một mô hình chấm điểm tốt có thể hỗ trợ tổ chức tín dụng đánh giá rủi ro, giảm thời gian xử lý hồ sơ và chuẩn hóa quy trình ra quyết định. Tuy nhiên, trong các bài toán có ảnh hưởng trực tiếp đến cơ hội kinh tế của con người, độ chính xác dự đoán không còn là tiêu chí duy nhất. Nếu mô hình đưa ra quyết định bất lợi một cách không cân xứng đối với một nhóm xã hội, hệ thống có thể tái tạo hoặc khuếch đại thiên lệch vốn có trong dữ liệu lịch sử.

Trong bài toán này, thuộc tính nhạy cảm được xét là gender. Nhóm male được xem là nhóm ưu thế, còn nhóm female là nhóm kém ưu thế. Kết quả thuận lợi là hồ sơ được dự đoán là good credit. Vấn đề chính không chỉ là mô hình có dự đoán đúng hay không, mà còn là liệu xác suất được phê duyệt, tỷ lệ đúng dương và tỷ lệ sai dương có chênh lệch đáng kể giữa hai nhóm hay không.

Một điểm quan trọng của bài toán fairness là việc bỏ trực tiếp biến nhạy cảm khỏi tập feature không đảm bảo mô hình công bằng. Các biến khác có thể chứa thông tin gián tiếp về gender, ví dụ tuổi, thời gian làm việc, mục đích vay hoặc số tiền vay. Khi các biến này vừa tiết lộ gender vừa ảnh hưởng mạnh đến quyết định tín dụng, chúng trở thành proxy đáng chú ý. Vì vậy, ngoài đánh giá performance và fairness, đồ án cũng phân tích proxy bằng SHAP để hiểu rõ hơn nguồn gốc của chênh lệch.

## 1.2 Mục tiêu nghiên cứu

Project hướng tới bốn mục tiêu:

1. Xây dựng pipeline tiền xử lý dữ liệu German Credit phù hợp với cross-validation, tránh data leakage và tách riêng target, gender, model features.

2. So sánh ba họ mô hình Logistic Regression, XGBoost và CatBoost trong các cấu hình có gender, không có gender, Reweighing và Reject Option Classification.
3. Đánh giá đồng thời hiệu năng dự đoán và fairness theo gender thông qua AUC, Balanced Accuracy, SPD, AOD và các chỉ số nhóm như approval rate, TPR, TNR, FPR.
4. Dùng SHAP để kiểm tra các proxy của gender, từ đó giải thích vì sao việc bỏ gender trực tiếp vẫn chưa đủ để loại bỏ chênh lệch.

## 1.3 Phạm vi và giả định

Bộ dữ liệu có kích thước nhỏ, chỉ gồm 1.000 mẫu. Vì vậy, kết quả trong báo cáo được hiểu như một nghiên cứu thực nghiệm có kiểm soát, không phải một hệ thống triển khai trực tiếp trong sản phẩm tài chính. Mục tiêu là so sánh phương pháp và phân tích trade-off giữa performance và fairness trên cùng một protocol.

Trong quá trình thực nghiệm, nhiều cấu hình đã được thử, bao gồm cả Exponentiated Gradient. Tuy nhiên, báo cáo chính chỉ tập trung vào các cấu hình được chốt cho phân tích cuối cùng: ba model có gender ban đầu, ba baseline không có gender, ba baseline với Reweighing và ba baseline với Reject Option Classification. Các thí nghiệm Exponentiated Gradient không được đưa vào bảng chính vì AUC suy giảm rõ rệt so với baseline.

## 1.4 Đóng góp của project

Đóng góp chính gồm:

- Một bộ thí nghiệm có cấu trúc để so sánh mô hình có gender, bỏ gender, Reweighing và Reject Option Classification.
- Một bộ bảng đánh giá bổ sung ở cấp nhóm, gồm male/female approval, TPR, TNR, male/female TPR và male/female FPR.
- Một phân tích proxy bằng SHAP giúp nối kết fairness metrics với các biến cụ thể trong dữ liệu.
- Kết luận thực nghiệm chọn hai phương án cuối: XGBoost + ROC cho hiệu năng tốt mà fairness cũng được cải thiện rất nhiều và Logistic Regression + ROC cho việc cải thiện hơn nữa về fairness nếu cần.

# Chương 2

# Tổng quan nghiên cứu liên quan

## 2.1 Credit scoring truyền thống và học máy

Credit scoring đã tồn tại trước khi học máy hiện đại trở nên phổ biến. Các hệ thống truyền thống thường dựa trên logistic regression, scorecard và các quy tắc nghiệp vụ được thiết kế bởi chuyên gia. Ưu điểm của hướng tiếp cận này là dễ giải thích, dễ kiểm soát và phù hợp với môi trường tài chính vốn yêu cầu audit. Tuy nhiên, khi dữ liệu tăng lên và quan hệ giữa các biến trở nên phức tạp, các mô hình tuyến tính có thể không khai thác hết thông tin trong dữ liệu.

Các mô hình boosting như XGBoost và CatBoost được dùng nhiều trong dữ liệu bảng vì có khả năng học quan hệ phi tuyến, tương tác giữa feature và xử lý nhiều dạng dữ liệu khác nhau. XGBoost nổi bật nhờ regularization và tối ưu hệ thống tốt [Chen and Guestrin, 2016]; CatBoost nổi bật ở cách xử lý categorical features native và giảm bias trong boosting [Prokhorenkova et al., 2018]. Trong bài toán credit scoring, các mô hình này thường đạt AUC cao hơn mô hình tuyến tính. Tuy nhiên, khả năng học mạnh cũng khiến chúng dễ khai thác các tín hiệu proxy phức tạp hơn.

Vì vậy không chỉ so sánh một mô hình tuyến tính với mô hình phi tuyến, mà còn đặt chúng trong cùng một khung fairness. Logistic Regression được giữ làm mô hình dễ giải thích; XGBoost đại diện cho lựa chọn hiệu năng cao; CatBoost đại diện cho hướng xử lý categorical feature tự nhiên hơn. Cách so sánh này phù hợp với thực tế: mô hình tốt nhất về AUC chưa chắc là mô hình phù hợp nhất nếu fairness gap lớn.

## 2.2 Fairness trong học máy

Fairness trong học máy có nhiều định nghĩa khác nhau. Một số định nghĩa tập trung vào công bằng theo cá nhân: những cá nhân tương tự nhau nên nhận quyết định tương tự. Một số định

nghĩa khác tập trung vào công bằng theo nhóm: các nhóm được xác định bởi thuộc tính nhạy cảm nên có kết quả thống kê tương đối cân bằng. Đồ án này chọn hướng fairness theo nhóm vì dữ liệu German Credit có protected attribute rõ ràng là gender, và mục tiêu là đo chênh lệch giữa male và female.

Hai tiêu chí quan trọng trong hướng nhóm là demographic parity và equalized odds. Demographic parity yêu cầu tỷ lệ kết quả thuận lợi không phụ thuộc vào protected group. SPD trong báo cáo là phiên bản hiệu số của ý tưởng này. Equalized odds yêu cầu TPR và FPR giữa các nhóm gần nhau [Hardt et al., 2016]; AOD trong báo cáo đo trung bình hai chênh lệch đó.

Trong credit scoring, fairness đặc biệt nhạy cảm vì quyết định tín dụng ảnh hưởng đến khả năng tiếp cận vốn, nhà ở, giáo dục và cơ hội kinh tế. Một mô hình có AUC cao nhưng làm giảm cơ hội của một nhóm xã hội có thể không được chấp nhận. Ngược lại, một mô hình chỉ tối ưu fairness nhưng làm giảm mạnh khả năng phân biệt rủi ro cũng khó triển khai trong tổ chức tài chính. Điểm cân bằng giữa hai phía là trọng tâm của project.

## 2.3 Các hướng giảm thiên lệch

Các phương pháp giảm thiên lệch thường được chia thành ba nhóm: pre-processing, in-processing và post-processing. Pre-processing chỉnh dữ liệu trước khi train; Reweighing là ví dụ điển hình [Kamiran and Calders, 2012]. In-processing thay đổi thuật toán học, ví dụ thêm constraint fairness trong quá trình tối ưu. Post-processing giữ nguyên mô hình nền nhưng chỉnh output cuối; Reject Option Classification thuộc nhóm này [Kamiran et al., 2012].

Mỗi nhóm có ưu và nhược điểm riêng. Pre-processing dễ áp dụng với nhiều mô hình, nhưng ảnh hưởng gián tiếp đến quyết định cuối. In-processing có thể tối ưu fairness chặt hơn nhưng phụ thuộc vào thuật toán và đôi khi làm giảm AUC. Post-processing có thể trực tiếp giảm SPD/AOD ở output, nhưng cần protected attribute ở giai đoạn ra quyết định và phải được giải thích cẩn thận về mặt chính sách.

Trong quá trình thực nghiệm, project có thử Exponentiated Gradient như một phương pháp in-processing. Tuy nhiên, kết quả AUC của nhóm này thấp hơn rõ so với baseline trong bài toán cụ thể này. Vì trọng tâm báo cáo là chọn cấu hình có trade-off tốt nhất cho đồ án, phần chính tập trung vào Reweighing và Reject Option Classification.

## 2.4 Explainability và proxy discrimination

Trong các hệ thống ra quyết định nhạy cảm, explainability không chỉ giúp hiểu mô hình mà còn hỗ trợ kiểm toán fairness. SHAP là một phương pháp phổ biến vì nó cung cấp giá trị đóng góp ở mức từng feature và có thể tổng hợp thành global importance [Lundberg and Lee,

2017]. Trong báo cáo này, SHAP được dùng theo hai cách: giải thích credit model và phát hiện proxy của gender.

Proxy discrimination xảy ra khi mô hình không dùng trực tiếp thuộc tính nhạy cảm nhưng dùng các biến khác mang thông tin tương quan với thuộc tính đó. Ví dụ, nếu một biến về việc làm hoặc nhà ở có phân phối khác nhau giữa male và female, mô hình có thể học thông tin gender gián tiếp. Việc này không nhất thiết luôn sai; một số biến proxy cũng có thể liên quan hợp lý đến rủi ro tín dụng. Tuy nhiên, chúng cần được phát hiện và đánh giá, nhất là khi đồng thời ảnh hưởng mạnh đến quyết định credit.

Đóng góp của project ở phần proxy là kết hợp hai nguồn SHAP: SHAP của mô hình phụ dự đoán gender và SHAP của mô hình credit baseline. Cách kết hợp này giúp phân biệt feature chỉ tiết lộ gender với feature vừa tiết lộ gender vừa ảnh hưởng đến quyết định.

## 2.5 Vị trí của project trong các hướng nghiên cứu

So với các nghiên cứu fairness quy mô lớn, project này có phạm vi nhỏ hơn và tập trung vào một dataset kinh điển. Điểm mạnh của project nằm ở pipeline thực nghiệm nhất quán: cùng một split dữ liệu, cùng metric, nhiều họ mô hình, nhiều chiến lược mitigation và phân tích proxy sau cùng. Điều này giúp kết quả dễ đọc và dễ kiểm chứng.

Một điểm khác biệt nữa là báo cáo không xem fairness mitigation như bước thay thế hoàn toàn explainability. Sau khi chọn ROC là phương pháp tốt nhất về metric, project vẫn quay lại kiểm tra proxy bằng SHAP để giải thích vì sao baseline chưa công bằng và vì sao cần monitoring nếu triển khai. Cách kết hợp đánh giá định lượng và diễn giải định tính làm báo cáo gần hơn với quy trình kiểm toán mô hình trong thực tế.

# Chương 3

# Cơ sở lý thuyết

## 3.1 Credit scoring như một bài toán phân loại nhị phân

Credit scoring trong project được mô hình hóa như bài toán phân loại nhị phân. Với mỗi hồ sơ vay, mô hình nhận vector đặc trưng $X$ và dự đoán xác suất $P(Y = 1 \mid X)$, trong đó $Y = 1$ tương ứng với good credit. Dự đoán nhãn cuối cùng được tạo bằng cách so sánh xác suất với một threshold, mặc định là 0.5 đối với baseline. Đối với các phương pháp post-processing như Reject Option Classification, threshold và reject margin được chọn từ dữ liệu huấn luyện bên trong, sau đó áp dụng lên test fold bên ngoài.

Một mô hình credit scoring thường được đánh giá bằng khả năng xếp hạng rủi ro và khả năng phân loại đúng. AUC đo chất lượng xếp hạng theo xác suất, còn Balanced Accuracy phù hợp khi phân phối nhãn không hoàn toàn cân bằng:

$$\text{BA} = \frac{1}{2}(\text{TPR} + \text{TNR}). \tag{3.1}$$

Trong đó TPR là tỷ lệ dự đoán đúng trong nhóm hồ sơ tốt, TNR là tỷ lệ dự đoán đúng trong nhóm hồ sơ xấu.

## 3.2 Fairness theo nhóm

Ta dùng fairness theo nhóm, tức so sánh hành vi của mô hình giữa nhóm female và nhóm male. Kết quả thuận lợi là dự đoán good credit. Hai metric chính là SPD và AOD, cùng họ ý tưởng với các ràng buộc fairness theo odds trong học có giám sát [Hardt et al., 2016].

Statistical Parity Difference được định nghĩa:

$$\text{SPD} = P(\hat{Y} = 1 \mid S = \text{female}) - P(\hat{Y} = 1 \mid S = \text{male}). \tag{3.2}$$

Nếu SPD âm, nhóm female có approval rate thấp hơn nhóm male. Nếu SPD gần 0, hai nhóm có tỷ lệ được phê duyệt gần nhau hơn. SPD chỉ nhìn vào đầu ra dự đoán và không điều kiện theo nhãn thật.

Average Odds Difference xét thêm nhãn thật:

$$\text{AOD} = \frac{1}{2}\left[(\text{FPR}_{female} - \text{FPR}_{male}) + (\text{TPR}_{female} - \text{TPR}_{male})\right]. \tag{3.3}$$

AOD gần 0 cho thấy chênh lệch về tỷ lệ đúng dương và sai dương giữa hai nhóm nhỏ hơn. Trong credit scoring, AOD hữu ích vì nó không chỉ hỏi "ai được phê duyệt nhiều hơn", mà còn hỏi mô hình có sai khác nhau giữa các nhóm hay không.

## 3.3 Reweighing

Reweighing là một phương pháp pre-processing [Kamiran and Calders, 2012]. Ý tưởng là không thay đổi nhãn hoặc feature, mà gán trọng số cho từng mẫu trong training data để giảm phụ thuộc giữa thuộc tính nhạy cảm $S$ và nhãn $Y$. Trọng số thường có dạng:

$$w(s, y) = \frac{P(S = s)P(Y = y)}{P(S = s, Y = y)}. \tag{3.4}$$

Nếu một tổ hợp nhóm/nhãn xuất hiện ít hơn kỳ vọng độc lập, mẫu thuộc tổ hợp đó sẽ nhận trọng số cao hơn. Khi mô hình học với sample weight này, loss function giảm ảnh hưởng của phân bố lệch trong dữ liệu lịch sử. Ưu điểm của Reweighing là đơn giản, có thể dùng với nhiều mô hình khác nhau và không cần sửa thuật toán học máy bên trong. Nhược điểm là nó không trực tiếp tối ưu fairness metric ở bước dự đoán cuối.

## 3.4 Reject Option Classification

Reject Option Classification là một phương pháp post-processing [Kamiran et al., 2012]. Phương pháp này xuất phát từ quan sát rằng các dự đoán gần ngưỡng quyết định thường không chắc chắn. Trong vùng "reject option", mô hình có thể điều chỉnh quyết định theo hướng có lợi hơn cho nhóm kém ưu thế và ít có lợi hơn cho nhóm ưu thế, với mục tiêu giảm chênh lệch fairness nhưng hạn chế ảnh hưởng tới hiệu năng.

Trong pipeline của project, threshold và reject margin không được chọn trên test fold bên ngoài. Với mỗi outer training fold, một vòng cross-validation bên trong tạo OOF prediction để chọn tham số ROC. Sau đó, bộ tham số đã chọn mới được áp dụng lên outer test fold. Cách làm này giữ đúng nguyên tắc đánh giá ngoài mẫu.

## 3.5 SHAP và phân tích proxy

SHAP giải thích dự đoán của mô hình bằng cách phân bổ đóng góp cho từng feature. Với một mẫu $x$, giá trị SHAP dương nghĩa là feature đẩy dự đoán theo hướng class dương, còn giá trị âm đẩy theo hướng ngược lại. Trung bình |SHAP| trên nhiều mẫu thường được dùng như một thước đo global importance [Lundberg and Lee, 2017].

Để kiểm tra proxy của gender, ta huấn luyện một mô hình phụ dự đoán gender từ các feature không chứa gender. Nếu mô hình phụ đạt AUC cao hơn 0.5, các feature còn lại đang chứa thông tin gián tiếp về gender. Sau đó, SHAP của mô hình phụ cho biết feature nào tiết lộ gender mạnh nhất. Để đánh giá rủi ro proxy trong credit decision, ta kết hợp hai đại lượng:

$$\text{ProxyRisk}(j) = \widetilde{I}_{gender}(j) \times \widetilde{I}_{credit}(j), \tag{3.5}$$

trong đó $\widetilde{I}_{gender}(j)$ là proxy importance đã chuẩn hóa của feature hoặc attribute $j$, còn $\widetilde{I}_{credit}(j)$ là importance đã chuẩn hóa của cùng feature/attribute trong mô hình credit baseline. Chỉ số này là heuristic sàng lọc, không phải bằng chứng nhân quả hoặc kết luận pháp lý.

# Chương 4

# Dữ liệu và tiền xử lý

## 4.1 Bộ dữ liệu German Credit

Bộ dữ liệu Statlog German Credit gồm 1.000 hồ sơ tín dụng [Hofmann, 1994]. Mỗi hồ sơ có các thông tin về lịch sử tín dụng, mục đích vay, số tiền vay, thời hạn vay, tình trạng tiết kiệm, thời gian làm việc, tài sản, nhà ở và một số thông tin cá nhân khác. Nhãn đích được chuyển thành `credit_good`, trong đó 1 là hồ sơ tốt và 0 là hồ sơ xấu.

Thuộc tính nhạy cảm gender được suy ra từ attribute 9 của dữ liệu gốc. Tuy nhiên, attribute 9 ban đầu là tổ hợp giữa personal status và sex. Nếu đưa trực tiếp biến này vào model, mô hình sẽ nhận cả thông tin hôn nhân/cá nhân lẫn giới tính trong cùng một mã. Vì vậy, ta chỉ dùng attribute này để tạo biến gender nhị phân, sau đó loại bỏ hoàn toàn personal status khỏi model features. Quy ước dùng xuyên suốt báo cáo là:

- `gender = 1`: male, nhóm ưu thế.
- `gender = 0`: female, nhóm kém ưu thế.
- `credit_good = 1`: kết quả thuận lợi.

## 4.2 Phân phối nhãn và gender

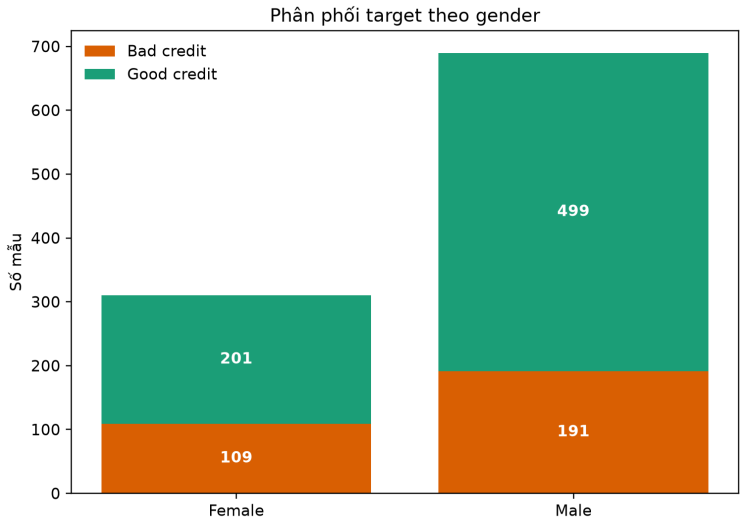
Bảng 4.1 tóm tắt phân phối nhãn và gender sau khi xử lý. Bộ dữ liệu có 700 hồ sơ good credit và 300 hồ sơ bad credit, nghĩa là nhãn thuận lợi chiếm đa số. Về gender, số mẫu male nhiều hơn female. Đây là bối cảnh quan trọng khi đọc fairness metrics: nếu một nhóm vừa ít mẫu hơn vừa có phân phối nhãn khác, các metric như TPR/FPR theo nhóm có thể dao động mạnh hơn giữa các fold.

Hình 4.1 biểu diễn phân phối target theo gender. Biểu đồ này cho thấy fairness không thể được đánh giá chỉ bằng accuracy tổng thể. Một mô hình có thể dự đoán tốt trên nhóm

Bảng 4.1: Phân phối nhãn và gender trong bộ dữ liệu sau xử lý.

| Nhóm | Số mẫu | Tỷ lệ |
|---|---|---|
| Tổng số mẫu | 1000 | 100.0% |
| Good credit | 700 | 70.0% |
| Bad credit | 300 | 30.0% |
| Male | 690 | 69.0% |
| Female | 310 | 31.0% |
| Male good credit | 499 | 49.9% |
| Female good credit | 201 | 20.1% |
| Male bad credit | 191 | 19.1% |
| Female bad credit | 109 | 10.9% |

đông hơn nhưng vẫn tạo sai lệch đối với nhóm ít mẫu hơn. Vì vậy, các fold trong project được stratify theo tổ hợp gender và target để giảm nguy cơ một fold thiếu một giao điểm quan trọng.




Hình 4.1: Phân phối good/bad credit theo gender.

## 4.3 Các thuộc tính sau khi loại bỏ personal status

Sau bước xử lý ban đầu, feature matrix còn 19 attribute gốc: 7 numeric và 12 categorical. Bảng 4.2 liệt kê các biến và cách xử lý.

## 4.4 Cross-validation và tránh data leakage

Dữ liệu được chia thành 5 fold. Mỗi fold có 800 mẫu training và 200 mẫu test. Việc chia fold được stratify theo tổ hợp $(gender, target)$ để các giao điểm giữa nhóm nhạy cảm và nhãn

Bảng 4.2: Các biến còn lại sau khi loại bỏ personal status.

| Nhóm | Biến | Xử lý |
|---|---|---|
| Numeric | duration_months | Min-Max scaling |
| Numeric | credit_amount | Min-Max scaling |
| Numeric | installment_rate | Min-Max scaling |
| Numeric | residence_since | Min-Max scaling |
| Numeric | age | Min-Max scaling |
| Numeric | existing_credits | Min-Max scaling |
| Numeric | dependents | Min-Max scaling |
| Categorical | checking_status | One-hot / CatBoost native |
| Categorical | credit_history | One-hot / CatBoost native |
| Categorical | purpose | One-hot / CatBoost native |
| Categorical | savings_status | One-hot / CatBoost native |
| Categorical | employment_since | One-hot / CatBoost native |
| Categorical | other_debtors | One-hot / CatBoost native |
| Categorical | property | One-hot / CatBoost native |
| Categorical | other_installment_plans | One-hot / CatBoost native |
| Categorical | housing | One-hot / CatBoost native |
| Categorical | job | One-hot / CatBoost native |
| Categorical | telephone | One-hot / CatBoost native |
| Categorical | foreign_worker | One-hot / CatBoost native |

thật tương đối ổn định giữa các fold.

Để tránh data leakage, mọi phép biến đổi học từ dữ liệu đều được fit riêng trên training fold:

- Numeric features được Min-Max scale về khoảng $[0, 1]$ bằng scaler fit trên training fold. Giá trị test nằm ngoài miền training được clip về $[0, 1]$.
- Categorical features được one-hot encode với encoder fit trên training fold. Đây là representation dùng cho Logistic Regression và XGBoost.
- CatBoost dùng categorical features nguyên bản thông qua cơ chế native categorical handling, nhưng vẫn dùng đúng train/test indices của các fold.
- Reweighing weights chỉ được tính trên training fold và chỉ truyền vào bước fit.

## 4.5 Các tập dữ liệu phục vụ thí nghiệm

Pipeline tạo hai dạng dữ liệu. Dạng thứ nhất nằm trong `data/processed/folds`, chứa dữ liệu đã one-hot và scale cho Logistic Regression/XGBoost. Dạng thứ hai nằm trong `data/processed/catboost_folds`, giữ categorical features ở dạng gốc cho CatBoost. Cả hai dạng dùng cùng một phân hoạch cross-validation, giúp so sánh giữa các họ mô hình công bằng hơn.

Gender được lưu trong mỗi fold để phục vụ fairness metric, Reweighing, ROC và phân tích theo nhóm. Trong baseline không có gender, biến này không nằm trong feature matrix. Trong nhóm thí nghiệm "with gender", gender được thêm lại có chủ đích để đo tác động khi mô hình được phép dùng trực tiếp thuộc tính nhạy cảm.

# Chương 5

# Phương pháp

## 5.1 Reweighing (RW)

Reweighing là phương pháp tiền xử lý được đề xuất nhằm giảm sự phụ thuộc giữa thuộc tính nhạy cảm và nhãn mục tiêu. Ý tưởng chính là gán trọng số khác nhau cho từng mẫu dữ liệu để sau khi huấn luyện trở nên công bằng hơn.

Giả sử:

- $A$: thuộc tính nhạy cảm (ví dụ: giới tính).
- $Y$: nhãn thực tế.
- $a \in \mathcal{A}$: giá trị của thuộc tính nhạy cảm.
- $y \in \{0, 1\}$: giá trị của nhãn.

Trọng số được gán cho mỗi nhóm $(A = a, Y = y)$ như sau:

$$w(a, y) = \frac{P(A = a)P(Y = y)}{P(A = a, Y = y)} \tag{5.1}$$

Trong đó:

- $P(A = a)$ là xác suất xuất hiện của nhóm nhạy cảm $a$.
- $P(Y = y)$ là xác suất của nhãn $y$.
- $P(A = a, Y = y)$ là xác suất đồng thời của nhóm $a$ và nhãn $y$.

Các mẫu thuộc những nhóm bị thiếu đại diện sẽ nhận trọng số lớn hơn, trong khi các nhóm xuất hiện quá nhiều sẽ nhận trọng số nhỏ hơn. Sau đó, các trọng số này được sử dụng trong quá trình huấn luyện mô hình.

Ưu điểm của Reweighing là không làm thay đổi cấu trúc của mô hình học máy và có thể áp dụng cho nhiều thuật toán khác nhau. Tuy nhiên, việc thay đổi trọng số mẫu có thể làm giảm hiệu năng dự đoán nếu sự đánh đổi giữa độ chính xác và công bằng quá lớn.

## 5.2 Reject Option Classification (ROC)

Reject Option Classification là phương pháp hậu xử lý được đề xuất nhằm điều chỉnh các dự đoán của mô hình sau khi quá trình huấn luyện hoàn tất.

Ý tưởng chính của ROC là chỉ thay đổi những dự đoán mà mô hình chưa thực sự chắc chắn, tức là các mẫu có xác suất dự đoán nằm gần ngưỡng phân loại.

Giả sử:

- $s(x)$ là điểm số dự đoán của mẫu $x$.
- $t$ là ngưỡng phân loại.
- $\theta$ là biên độ vùng không chắc chắn (critical region).

Vùng không chắc chắn được xác định bởi:

$$t - \theta \leq s(x) \leq t + \theta \tag{5.2}$$

Đối với các mẫu nằm trong vùng này:

- Nếu thuộc nhóm được ưu tiên (privileged group), ROC có xu hướng gán nhãn bất lợi.
- Nếu thuộc nhóm không được ưu tiên (unprivileged group), ROC có xu hướng gán nhãn có lợi.

Những mẫu nằm ngoài vùng không chắc chắn vẫn giữ nguyên kết quả dự đoán ban đầu.

Giả sử:

$$\hat{Y} = f(X) \tag{5.3}$$

là dự đoán ban đầu của mô hình. Sau khi áp dụng ROC, đầu ra mới được ký hiệu là

$$\hat{Y}_{ROC} = g(\hat{Y}, A, s(X)) \tag{5.4}$$

trong đó:

- $\hat{Y}$ là nhãn dự đoán ban đầu;
- $A$ là thuộc tính nhạy cảm;
- $s(X)$ là xác suất hoặc điểm số dự đoán của mô hình.

Do chỉ tác động đến các mẫu nằm gần ranh giới quyết định, ROC thường duy trì được độ chính xác của mô hình trong khi cải thiện các chỉ số công bằng như Statistical Parity Difference (SPD) và Average Odds Difference (AOD). Tuy nhiên, phương pháp này phụ thuộc vào việc lựa chọn ngưỡng và kích thước vùng không chắc chắn, đồng thời chỉ có thể áp dụng khi mô hình cung cấp xác suất hoặc điểm số dự đoán.

# Chương 6

# Thiết kế thực nghiệm

## 6.1 Danh sách cấu hình

Báo cáo chính xét 12 cấu hình, chia thành bốn nhóm:

1. Ba mô hình có gender: Logistic Regression + gender, XGBoost + gender, CatBoost + gender.
2. Ba baseline không có gender: Logistic Regression baseline, XGBoost baseline, CatBoost baseline.
3. Ba baseline không có gender kết hợp Reweighing: Logistic Regression + RW, XGBoost + RW, CatBoost + RW.
4. Ba baseline không có gender kết hợp Reject Option Classification: Logistic Regression + ROC, XGBoost + ROC, CatBoost + ROC.

Exponentiated Gradient không được đưa vào phân tích chính. Lý do là các kết quả thử nghiệm ban đầu cho thấy AUC giảm đáng kể so với baseline, trong khi mục tiêu báo cáo cuối cùng là chọn mô hình có trade-off tốt giữa AUC, SPD và AOD.

## 6.2 Protocol đánh giá

Tất cả cấu hình dùng 5-fold cross-validation. Với mỗi fold:

- Train model trên 800 mẫu training.
- Lưu model dưới dạng Joblib để test/predict lại không cần train lại.
- Dự đoán trên 200 mẫu held-out test.

- Tính AUC, Balanced Accuracy, SPD, AOD và các group metrics.

Kết quả chính trong Bảng 7.1 là mean và standard deviation trên 5 fold. Bảng phụ trong Bảng 7.3 dùng toàn bộ 1.000 out-of-fold predictions để mô tả trực quan hơn approval rate và error rate theo gender.

## 6.3 Các metric

Performance được đánh giá bằng:

- AUC: khả năng xếp hạng hồ sơ tốt cao hơn hồ sơ xấu.
- Balanced Accuracy: trung bình giữa TPR và TNR, phù hợp khi cần cân bằng giữa phát hiện hồ sơ tốt và loại hồ sơ xấu.

Fairness được đánh giá bằng:

- SPD: female approval rate trừ male approval rate.
- AOD: trung bình chênh lệch FPR và TPR giữa female và male.
- Male/Female Approval: tỷ lệ được dự đoán good credit của từng nhóm.
- Male/Female TPR: tỷ lệ hồ sơ thật sự tốt được phê duyệt trong từng nhóm.
- Male/Female FPR: tỷ lệ hồ sơ thật sự xấu nhưng vẫn được phê duyệt trong từng nhóm.

Trong diễn giải, giá trị tuyệt đối của SPD và AOD càng nhỏ càng tốt. Tuy nhiên, fairness không nên được tối ưu bằng mọi giá nếu làm hiệu năng suy giảm mạnh. Do đó, lựa chọn cuối cùng dựa trên cả AUC, Balanced Accuracy, SPD và AOD.

## 6.4 Kiểm soát độ ổn định giữa các fold

Vì German Credit chỉ có 1.000 mẫu, kết quả trên từng fold có thể dao động. Do đó, báo cáo luôn trình bày mean và standard deviation trên 5 fold thay vì chỉ dùng một train/test split. Với hai mô hình cuối cùng, Bảng 7.5 trong chương kết quả còn liệt kê metric theo từng fold để kiểm tra độ ổn định cụ thể hơn.

Khi đọc bảng theo fold, cần chú ý hai điều. Thứ nhất, AUC đo ranking nên không thay đổi sau ROC nếu ROC chỉ điều chỉnh nhãn dự đoán mà giữ nguyên score gốc. Thứ hai, SPD/AOD có thể dao động theo fold vì số mẫu female/male ở từng fold không lớn. Vì vậy, kết luận cuối cùng dựa trên xu hướng tổng thể, không dựa vào một fold đơn lẻ.

# Chương 7

# Kết quả thực nghiệm

## 7.1 Tổng quan hiệu năng và fairness

Bảng 7.1 trình bày kết quả chính của 12 cấu hình. Nhìn tổng thể, các mô hình có gender đạt AUC tương đương baseline không có gender nhưng tạo fairness gap lớn hơn rõ rệt. Logistic Regression + gender có SPD trung bình -0.107 và AOD -0.098; XGBoost + gender có SPD -0.090 và AOD -0.063; CatBoost + gender có SPD -0.081 và AOD -0.065. Dấu âm cho thấy nhóm female có tỷ lệ được dự đoán tốt thấp hơn nhóm male.

Bảng 7.1: Hiệu năng và fairness theo 5-fold cross-validation trên 12 cấu hình được chọn cho báo cáo.

| Model | Feature/mitigation | AUC | BA | SPD | AOD |
|---|---|---|---|---|---|
| Logistic Regression | Gender feature | 0.789 ± 0.050 | 0.672 ± 0.048 | -0.107 ± 0.047 | -0.098 ± 0.043 |
| XGBoost | Gender feature | 0.790 ± 0.026 | 0.672 ± 0.022 | -0.090 ± 0.063 | -0.063 ± 0.060 |
| CatBoost | Gender feature | 0.788 ± 0.029 | 0.648 ± 0.022 | -0.081 ± 0.076 | -0.065 ± 0.093 |
| Logistic Regression | No gender | 0.788 ± 0.051 | 0.666 ± 0.040 | -0.053 ± 0.057 | -0.038 ± 0.054 |
| XGBoost | No gender | 0.795 ± 0.026 | 0.667 ± 0.021 | -0.057 ± 0.079 | -0.027 ± 0.085 |
| CatBoost | No gender | 0.783 ± 0.031 | 0.656 ± 0.028 | -0.042 ± 0.089 | -0.026 ± 0.110 |
| Logistic Regression | Reweighing | 0.787 ± 0.051 | 0.666 ± 0.048 | -0.036 ± 0.045 | -0.015 ± 0.047 |
| XGBoost | Reweighing | 0.791 ± 0.028 | 0.672 ± 0.033 | -0.062 ± 0.082 | -0.033 ± 0.080 |
| CatBoost | Reweighing | 0.787 ± 0.026 | 0.649 ± 0.023 | -0.032 ± 0.056 | -0.018 ± 0.070 |
| Logistic Regression | Reject Option | 0.788 ± 0.051 | 0.698 ± 0.040 | -0.019 ± 0.045 | 0.000 ± 0.018 |
| XGBoost | Reject Option | 0.795 ± 0.026 | 0.723 ± 0.016 | -0.032 ± 0.088 | -0.006 ± 0.073 |
| CatBoost | Reject Option | 0.783 ± 0.031 | 0.709 ± 0.032 | -0.027 ± 0.068 | -0.001 ± 0.063 |

Khi bỏ gender khỏi feature matrix, fairness được cải thiện nhưng không biến mất. Logistic baseline giảm SPD từ -0.107 xuống -0.053 và AOD từ -0.098 xuống -0.038. XGBoost baseline có AUC cao nhất trong nhóm baseline, 0.795, nhưng SPD vẫn ở mức -0.057. CatBoost baseline có SPD thấp hơn, -0.042, nhưng Balanced Accuracy cũng thấp hơn so với XGBoost.

## 7.2 Phân tích từng phương pháp cải thiện công bằng

Bảng 7.2 trình bày trực tiếp mức thay đổi của từng phương pháp. Với "Remove gender", mốc so sánh là mô hình cùng họ có gender. Với Reweighing và ROC, mốc so sánh là baseline không có gender cùng họ mô hình. Hai cột "Giảm |SPD|" và "Giảm |AOD|" dùng trị tuyệt đối của fairness gap; giá trị dương nghĩa là chênh lệch giữa hai nhóm giảm, giá trị âm nghĩa là fairness xấu hơn theo metric đó.

Bảng 7.2: Thay đổi performance và fairness của từng phương pháp so với mốc tham chiếu. Remove gender so với model có gender; RW và ROC so với baseline không có gender. Giá trị giảm của |SPD|/|AOD| dương nghĩa là fairness được cải thiện.

| Model | Method | dAUC | dBA | \|SPD\| | d\|SPD\| | \|AOD\| | d\|AOD\| |
|---|---|---|---|---|---|---|---|
| LR | Drop gender | -0.001 | -0.006 | 0.107→0.053 | +0.054 | 0.098→0.038 | +0.061 |
| LR | RW | -0.001 | +0.000 | 0.053→0.036 | +0.018 | 0.038→0.015 | +0.023 |
| LR | ROC | +0.000 | +0.032 | 0.053→0.019 | +0.034 | 0.038→0.000 | +0.037 |
| XGBoost | Drop gender | +0.005 | -0.005 | 0.090→0.057 | +0.033 | 0.063→0.027 | +0.036 |
| XGBoost | RW | -0.004 | +0.005 | 0.057→0.062 | -0.005 | 0.027→0.033 | -0.006 |
| XGBoost | ROC | +0.000 | +0.056 | 0.057→0.032 | +0.025 | 0.027→0.006 | +0.021 |
| CatBoost | Drop gender | -0.005 | +0.009 | 0.081→0.042 | +0.040 | 0.065→0.026 | +0.039 |
| CatBoost | RW | +0.004 | -0.007 | 0.042→0.032 | +0.009 | 0.026→0.018 | +0.008 |
| CatBoost | ROC | +0.000 | +0.052 | 0.042→0.027 | +0.015 | 0.026→0.001 | +0.025 |

### 7.2.1 Loại bỏ Gender

Việc loại bỏ gender trực tiếp khỏi feature matrix giúp giảm bias rõ rệt nhưng không giải quyết triệt để. Với Logistic Regression, AUC gần như không đổi: 0.789 ở bản có gender và 0.788 ở baseline không gender. Trong khi đó, |SPD| giảm từ 0.107 xuống 0.053 và |AOD| giảm từ 0.098 xuống 0.038. Đây là kết quả quan trọng: gender không cần thiết để giữ hiệu năng dự đoán của Logistic Regression, nhưng việc bỏ gender làm fairness tốt hơn đáng kể.

Với XGBoost, bỏ gender còn làm AUC tăng nhẹ từ 0.790 lên 0.795, đồng thời |SPD| giảm từ 0.090 xuống 0.057 và |AOD| giảm từ 0.063 xuống 0.027. Với CatBoost, AUC giảm rất nhẹ từ 0.788 xuống 0.783, nhưng fairness cải thiện: |SPD| giảm từ 0.081 xuống 0.042 và |AOD| giảm từ 0.065 xuống 0.026.

Kết luận là bỏ gender là bước cần thiết và gần như không làm mất performance, nhưng chưa đủ. Các baseline không có gender vẫn còn SPD âm và AOD khác 0. Điều này cho thấy mô hình vẫn có thể học thông tin liên quan đến gender thông qua proxy features, chẳng hạn `purpose`, `employment_since`, `credit_amount`, `age` hoặc `checking_status`.

### 7.2.2 Reweighing (RW)

Reweighing nhìn chung cải thiện fairness vừa phải. Logistic Regression + RW giảm SPD xuống -0.036 và AOD xuống -0.015, trong khi AUC gần như giữ nguyên so với Logistic

baseline. CatBoost + RW cũng giảm AOD xuống -0.018. Tuy nhiên, XGBoost + RW không cải thiện SPD so với baseline; SPD chuyển từ -0.057 sang -0.062, còn AOD từ -0.027 sang -0.033. Điều này cho thấy Reweighing không phải lúc nào cũng đủ mạnh, đặc biệt với mô hình phi tuyến có khả năng khai thác proxy phức tạp.

Nếu xét trade-off, RW đáng dùng với Logistic Regression và CatBoost vì AUC gần như không giảm, trong khi |SPD| và |AOD| đều giảm. Với Logistic Regression, |AOD| giảm khoảng 0.023 điểm so với baseline; với CatBoost, |AOD| giảm khoảng 0.008 điểm. Tuy nhiên, RW không phải lựa chọn cuối cùng vì mức cải thiện thấp hơn ROC. Đối với XGBoost, RW còn làm cả |SPD| và |AOD| tăng nhẹ, nên không đáng đánh đổi trong cấu hình hiện tại.

### 7.2.3 Reject Option Classification (ROC)

ROC là phương pháp tạo cải thiện rõ nhất trong bộ thí nghiệm. Logistic Regression + ROC giữ AUC bằng baseline vì post-processing không thay đổi xác suất xếp hạng, nhưng Balanced Accuracy tăng từ 0.666 lên 0.698. Đồng thời SPD giảm từ -0.053 xuống -0.019 và AOD gần như bằng 0.

XGBoost + ROC là cấu hình mạnh nhất về hiệu năng trong các mô hình được chọn: AUC 0.795, Balanced Accuracy 0.723, SPD -0.032 và AOD -0.006. So với XGBoost baseline, Balanced Accuracy tăng đáng kể từ 0.667 lên 0.723, trong khi AOD tiến gần 0 hơn. Đây là lý do XGBoost + ROC được chọn làm mô hình chính về performance.

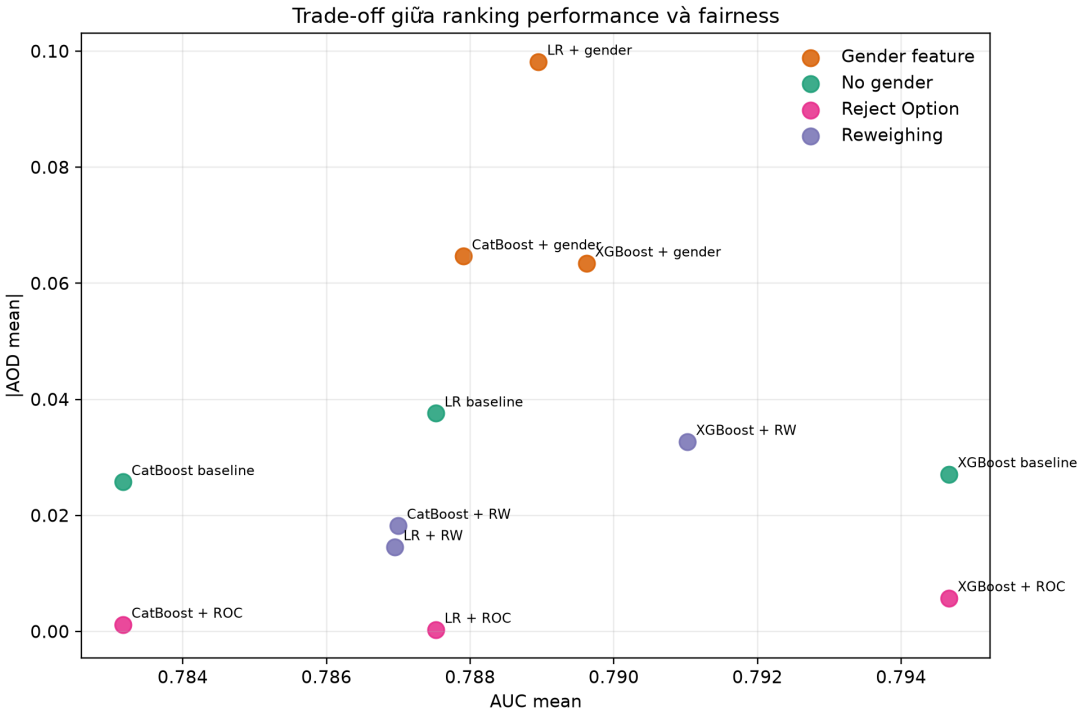
CatBoost + ROC cũng là một comparator rất tốt về fairness, với AOD -0.001 và SPD -0.027. Tuy nhiên, AUC của CatBoost + ROC là 0.783, thấp hơn XGBoost + ROC và không vượt Logistic + ROC về khả năng diễn giải. Vì vậy, trong phần kết luận, CatBoost + ROC được xem là phương án cạnh tranh nhưng không phải mô hình cuối cùng.

ROC làm AOD gần 0 vì phương pháp này can thiệp trực tiếp ở bước post-processing, tức sau khi mô hình nền đã tạo xác suất. Các dự đoán nằm gần threshold được xem là vùng không chắc chắn; trong vùng này, ROC điều chỉnh nhãn theo hướng giảm chênh lệch giữa nhóm female và male. Vì AOD phụ thuộc trực tiếp vào TPR và FPR theo nhóm, việc điều chỉnh nhãn ở vùng sát ngưỡng có thể kéo chênh lệch TPR/FPR về gần 0 mà không cần thay đổi toàn bộ ranking của mô hình. Đây cũng là lý do AUC của ROC giữ nguyên so với baseline: AUC dùng score xác suất gốc để đo khả năng xếp hạng, còn ROC chủ yếu thay đổi nhãn cuối cùng sau threshold.

## 7.3 Trade-off giữa AUC và AOD

Hình 7.1 biểu diễn trade-off giữa AUC trung bình và |AOD|. Điểm tốt nằm gần góc dưới bên phải: AUC cao và AOD gần 0. Nhóm có gender nằm cao hơn do AOD lớn. Nhóm ROC dịch

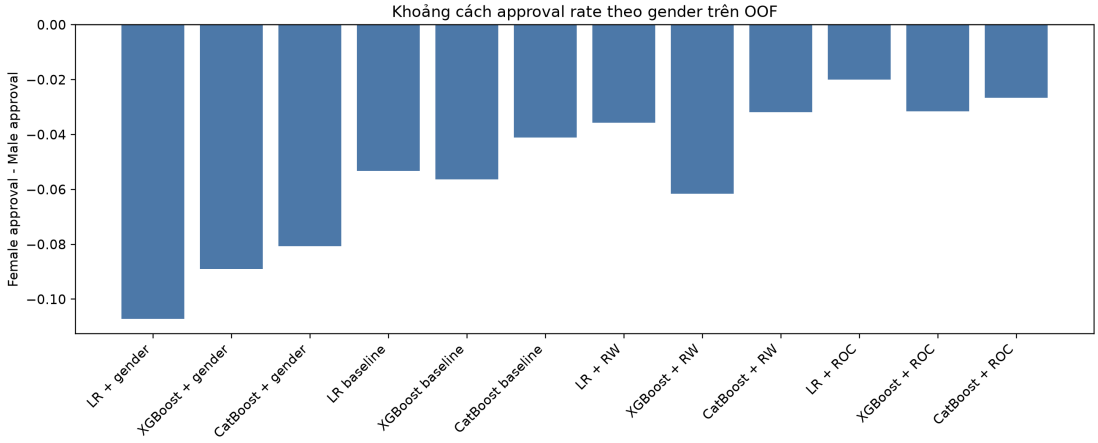
chuyển rõ rệt xuống dưới, cho thấy post-processing xử lý tốt chênh lệch odds.




Hình 7.1: Trade-off giữa AUC và trị tuyệt đối AOD của 12 cấu hình.

## 7.4 Approval gap theo gender

Hình 7.2 cho thấy female approval rate trừ male approval rate trên toàn bộ OOF predictions. Hầu hết cấu hình có giá trị âm, nghĩa là female vẫn được phê duyệt ít hơn male. Tuy nhiên, khoảng cách này giảm mạnh ở nhóm ROC, đặc biệt với Logistic Regression + ROC và CatBoost + ROC.




Hình 7.2: Khoảng cách approval rate theo gender trên OOF predictions.

## 7.5 Bảng phụ theo nhóm

Bảng 7.3 bổ sung các thông tin chi tiết hơn: Male Approval, Female Approval, TPR, TNR, Male/Female TPR và Male/Female FPR. Bảng này giúp diễn giải SPD/AOD bằng các tỷ lệ cụ thể. Ví dụ, với XGBoost + ROC, male approval là 60.6%, female approval là 57.4%; female TPR là 74.1% và male TPR là 72.5%. Điều này cho thấy sau ROC, mô hình không còn đơn giản là hy sinh female TPR để tăng fairness; thực tế female TPR nhỉnh hơn male TPR, trong khi female FPR thấp hơn male FPR.

Bảng 7.3: Bảng phụ về approval rate, TPR, TNR và FPR theo gender trên 1.000 dự đoán out-of-fold.

| Model | Method | Male Appr. | Female Appr. | TPR | TNR | Male TPR | Female TPR | Male FPR | Female FPR |
|---|---|---|---|---|---|---|---|---|---|
| Logistic Regression | Gender feature | 80.7% | 70.0% | 87.7% | 46.7% | 89.2% | 84.1% | 58.6% | 44.0% |
| XGBoost | Gender feature | 81.2% | 72.3% | 88.7% | 45.7% | 90.6% | 84.1% | 56.5% | 50.5% |
| CatBoost | Gender feature | 84.2% | 76.1% | 90.6% | 39.0% | 92.0% | 87.1% | 63.9% | 56.0% |
| Logistic Regression | No gender | 78.6% | 73.2% | 86.9% | 46.3% | 87.2% | 86.1% | 56.0% | 49.5% |
| XGBoost | No gender | 80.1% | 74.5% | 88.4% | 45.0% | 89.6% | 85.6% | 55.5% | 54.1% |
| CatBoost | No gender | 82.2% | 78.1% | 90.3% | 41.0% | 90.4% | 90.0% | 60.7% | 56.0% |
| Logistic Regression | Reweighing | 78.4% | 74.8% | 87.3% | 46.0% | 87.4% | 87.1% | 55.0% | 52.3% |
| XGBoost | Reweighing | 79.7% | 73.5% | 88.1% | 46.3% | 89.4% | 85.1% | 54.5% | 52.3% |
| CatBoost | Reweighing | 83.2% | 80.0% | 91.1% | 38.7% | 91.0% | 91.5% | 62.8% | 58.7% |
| Logistic Regression | Reject Option | 62.3% | 60.3% | 73.6% | 66.0% | 72.7% | 75.6% | 35.1% | 32.1% |
| XGBoost | Reject Option | 60.6% | 57.4% | 73.0% | 71.7% | 72.5% | 74.1% | 29.3% | 26.6% |
| CatBoost | Reject Option | 60.7% | 58.1% | 72.4% | 69.3% | 71.9% | 73.6% | 31.4% | 29.4% |

## 7.6 Hai mô hình được chọn

Bảng 7.4 tóm tắt hai mô hình cuối cùng. Logistic Regression + ROC là lựa chọn cân bằng và dễ giải thích, với AOD gần bằng 0 và SPD -0.020. XGBoost + ROC là lựa chọn mạnh nhất về performance, với AUC 0.793 trên OOF và Balanced Accuracy 0.723, trong khi fairness vẫn được kiểm soát ở mức tốt.

Bảng 7.4: So sánh chi tiết hai mô hình cuối cùng được chọn: Logistic Regression + ROC và XGBoost + ROC.

| Model | AUC | BA | SPD | AOD | Male Appr. | Female Appr. | Male TPR | Female TPR |
|---|---|---|---|---|---|---|---|---|
| LR + ROC | 0.783 | 0.698 | -0.020 | -0.000 | 62.3% | 60.3% | 72.7% | 75.6% |
| XGBoost + ROC | 0.793 | 0.723 | -0.032 | -0.006 | 60.6% | 57.4% | 72.5% | 74.1% |

Bảng 7.5 cho thấy kết quả theo từng fold của hai mô hình được chọn. XGBoost + ROC có Balanced Accuracy ổn định ở mức cao hơn Logistic Regression + ROC trong hầu hết fold. Logistic Regression + ROC có AOD dao động nhỏ hơn, phản ánh ưu thế về cân bằng odds. Riêng SPD vẫn có dao động theo fold vì approval rate phụ thuộc mạnh vào số lượng male/female trong 200 mẫu test của từng fold.

Bảng 7.5: Metric theo từng fold của hai mô hình cuối cùng, dùng để kiểm tra độ ổn định giữa các lần chia dữ liệu.

| Model | Fold | AUC | BA | SPD | AOD |
|---|---|---|---|---|---|
| LR + ROC | 1 | 0.806 | 0.735 | -0.070 | -0.024 |
| LR + ROC | 2 | 0.852 | 0.732 | 0.001 | -0.005 |
| LR + ROC | 3 | 0.739 | 0.643 | -0.030 | -0.004 |
| LR + ROC | 4 | 0.731 | 0.670 | -0.045 | 0.008 |
| LR + ROC | 5 | 0.810 | 0.710 | 0.047 | 0.026 |
| XGBoost + ROC | 1 | 0.796 | 0.707 | -0.084 | -0.031 |
| XGBoost + ROC | 2 | 0.834 | 0.733 | 0.046 | 0.054 |
| XGBoost + ROC | 3 | 0.780 | 0.711 | -0.044 | -0.037 |
| XGBoost + ROC | 4 | 0.765 | 0.720 | -0.143 | -0.097 |
| XGBoost + ROC | 5 | 0.798 | 0.745 | 0.067 | 0.082 |

Nếu mục tiêu triển khai ưu tiên hiệu năng dự đoán, XGBoost + ROC là lựa chọn phù hợp hơn. Nếu mục tiêu ưu tiên giải thích, báo cáo cho hội đồng hoặc kiểm soát mô hình, Logistic Regression + ROC là lựa chọn đáng tin cậy hơn vì cấu trúc tuyến tính và SHAP dễ diễn giải.

# Chương 8

# Phân tích proxy của gender bằng SHAP

## 8.1 Động cơ

Kết quả ở Chương 7 cho thấy việc bỏ gender khỏi feature matrix làm giảm SPD/AOD, nhưng không đưa fairness gap về 0. Điều này là hợp lý vì dữ liệu còn nhiều biến có thể tương quan với gender. Ví dụ, trong một xã hội hoặc một bộ dữ liệu lịch sử cụ thể, tuổi, tình trạng nhà ở, thời gian làm việc, mục đích vay hoặc số tiền vay có thể mang thông tin gián tiếp về gender. Nếu mô hình sử dụng các biến này để ra quyết định, việc bỏ gender trực tiếp vẫn chưa đủ.

Proxy analysis trong project không nhằm kết luận một feature là bất hợp pháp hay gây phân biệt đối xử theo nghĩa nhân quả. Mục tiêu thực tế hơn là sàng lọc: feature nào tiết lộ gender, feature nào đồng thời ảnh hưởng mạnh đến credit prediction, và feature nào cần được kiểm tra kỹ hơn khi xây dựng mô hình.

## 8.2 Proxy analysis với Logistic Regression

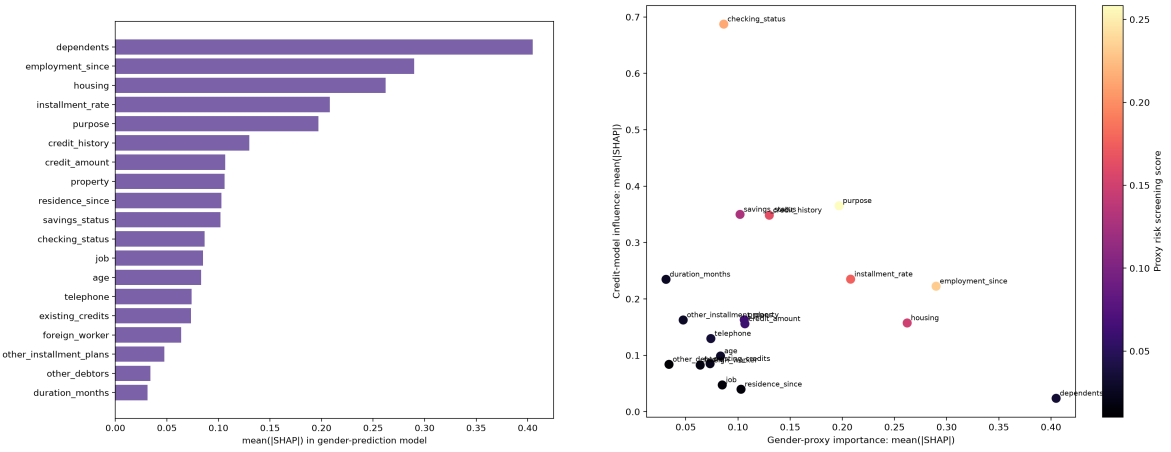
Mô hình phụ Logistic Regression dự đoán gender từ 57 feature không chứa gender đạt OOF AUC khoảng 0.689. Giá trị này cao hơn 0.5, nghĩa là các feature còn lại có tín hiệu dự đoán gender ở mức vừa phải. SHAP của mô hình phụ được gộp từ one-hot feature về 19 attribute gốc để phân tích ở mức dễ hiểu hơn.

Bảng 8.1 cho thấy `purpose`, `employment_since`, `checking_status` và `installment_rate` nằm trong nhóm proxy-risk cao nhất. Một điểm đáng chú ý là `dependents` có thể là tín hiệu proxy mạnh, nhưng ảnh hưởng của nó lên credit model thấp, nên proxy-risk không nằm đầu bảng. Điều này minh họa lý do cần kết hợp proxy importance và credit importance thay vì chỉ nhìn khả năng dự đoán gender.

Hình 8.2 cho biết hướng tác động của từng feature trong mô hình phụ Logistic Regression. Các điểm nằm bên phải làm tăng log-odds dự đoán male, các điểm nằm bên trái làm giảm

Bảng 8.1: Tám attribute có proxy-risk cao nhất theo model Logistic Regression dự đoán gender.

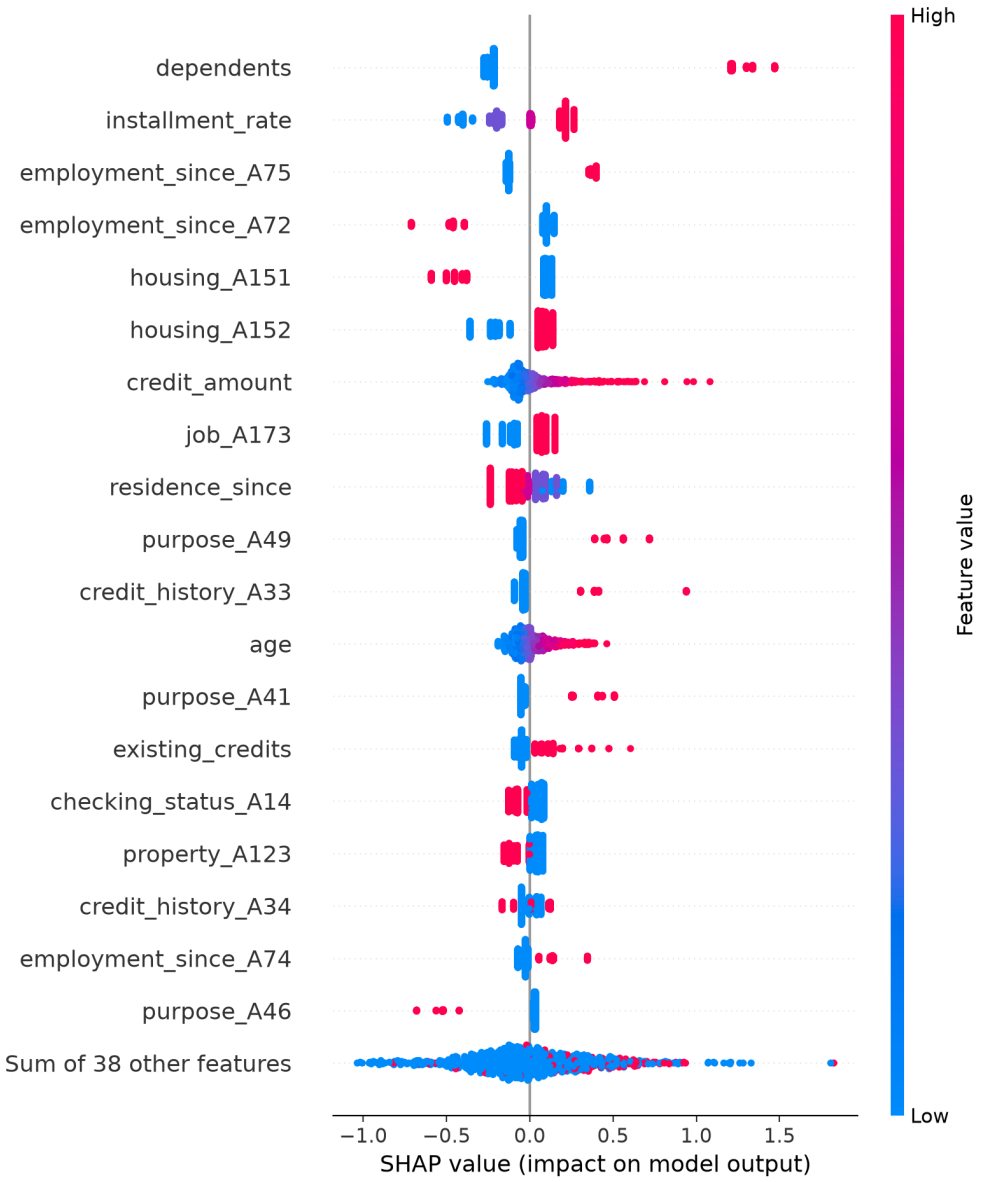
| Attribute | Proxy SHAP | Credit SHAP | Risk | Standalone AUC |
|---|---|---|---|---|
| purpose | 0.197 | 0.365 | 0.258 | 0.562 |
| employment_since | 0.290 | 0.222 | 0.232 | 0.610 |
| checking_status | 0.086 | 0.687 | 0.213 | 0.539 |
| installment_rate | 0.208 | 0.235 | 0.176 | 0.537 |
| credit_history | 0.130 | 0.348 | 0.163 | 0.531 |
| housing | 0.262 | 0.157 | 0.148 | 0.593 |
| savings_status | 0.102 | 0.350 | 0.128 | 0.522 |
| property | 0.106 | 0.163 | 0.062 | 0.513 |




(a) Proxy importance (b) Proxy-risk

Hình 8.1: Phân tích proxy bằng Logistic Regression.

log-odds dự đoán male. Với các biến one-hot, màu sắc thể hiện giá trị 0/1 của dummy feature. Khi một dummy category có cụm điểm đỏ lệch mạnh sang một phía, category đó mang thông tin đáng kể về gender.




Hình 8.2: SHAP beeswarm của mô hình phụ Logistic Regression dự đoán gender.

## 8.3 Proxy analysis với XGBoost

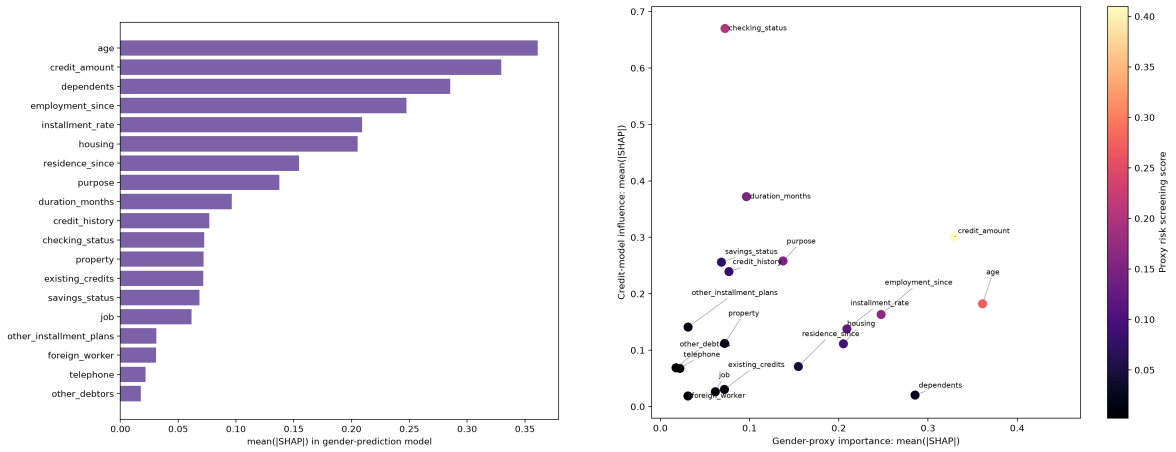
Mô hình phụ XGBoost dự đoán gender đạt OOF AUC khoảng 0.712, cao hơn Logistic Regression. Điều này cho thấy quan hệ giữa các feature còn lại và gender có thể chứa tương tác phi tuyến mà XGBoost khai thác tốt hơn.

Trong Bảng 8.2, `credit_amount` và `age` là hai attribute đáng chú ý nhất. `age` có proxy SHAP cao nhất và standalone gender AUC khoảng 0.642; `credit_amount` có proxy-risk cao

Bảng 8.2: Tám attribute có proxy-risk cao nhất theo model XGBoost dự đoán gender.

| Attribute | Proxy SHAP | Credit SHAP | Risk | Standalone AUC |
|---|---|---|---|---|
| credit_amount | 0.329 | 0.301 | 0.410 | 0.546 |
| age | 0.361 | 0.182 | 0.272 | 0.642 |
| checking_status | 0.072 | 0.670 | 0.201 | 0.535 |
| employment_since | 0.247 | 0.163 | 0.167 | 0.610 |
| duration_months | 0.096 | 0.372 | 0.148 | 0.508 |
| purpose | 0.137 | 0.258 | 0.147 | 0.564 |
| installment_rate | 0.209 | 0.138 | 0.119 | 0.527 |
| housing | 0.205 | 0.111 | 0.094 | 0.594 |

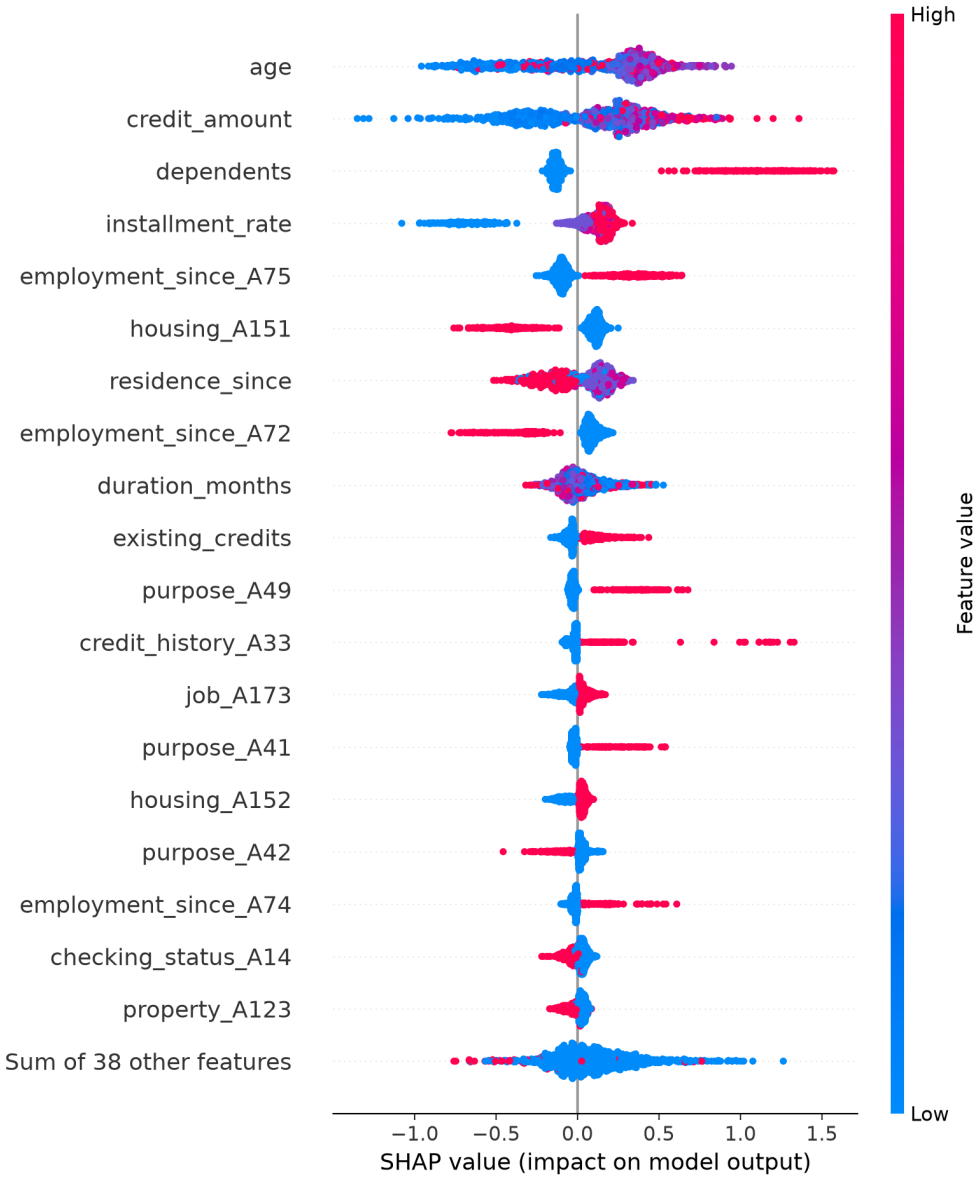
nhất vì vừa tiết lộ gender vừa có ảnh hưởng đáng kể trong credit baseline. `checking_status` có proxy SHAP không quá cao nhưng credit SHAP rất lớn, nên vẫn nằm trong nhóm rủi ro cao.




(a) Proxy importance (b) Proxy-risk

Hình 8.3: Phân tích proxy bằng XGBoost.

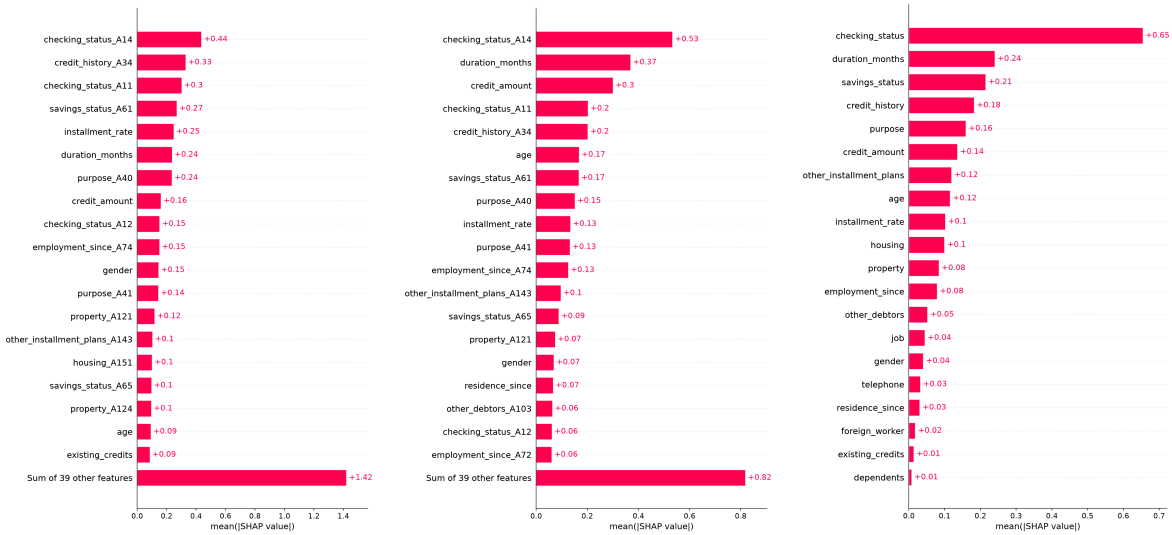
Hình 8.4 cho thấy XGBoost tìm được nhiều quan hệ phi tuyến hơn so với Logistic Regression. Các feature như `age`, `credit_amount`, `dependents` và một số category của `employment_since`/`housing` có phân bố SHAP tách rõ hơn giữa hai phía. Đây là lý do XGBoost proxy model đạt AUC cao hơn mô hình tuyến tính.




Hình 8.4: SHAP beeswarm của mô hình phụ XGBoost dự đoán gender.

## 8.4 SHAP của mô hình có gender

Ngoài proxy analysis, SHAP summary của các mô hình có gender giúp kiểm tra xem gender có xuất hiện như một feature quan trọng hay không. Hình 8.5 trình bày global importance của ba mô hình khi gender được đưa trực tiếp vào feature matrix. Kết quả này nên được đọc cùng với fairness metrics: nếu một model có gender vừa dùng gender đáng kể vừa tạo SPD/AOD lệch, đó là tín hiệu mạnh để không dùng cấu hình này làm mô hình cuối.




(a) Logistic Regression (b) XGBoost (c) CatBoost

Hình 8.5: SHAP summary bar của ba mô hình có gender.

## 8.5 Ý nghĩa đối với lựa chọn mô hình

Proxy analysis củng cố kết luận rằng fairness không thể chỉ dựa vào thao tác bỏ gender. Khi XGBoost phụ dự đoán gender đạt AUC 0.712, mô hình credit vẫn có khả năng học thông tin gender gián tiếp qua các biến khác. Điều này giải thích vì sao baseline không có gender vẫn có SPD/AOD lệch và vì sao ROC giúp cải thiện nhiều hơn: ROC can thiệp ở đầu ra cuối cùng theo nhóm nhạy cảm, thay vì chỉ cố thay đổi phân phối training.

Đối với XGBoost + ROC, cần lưu ý rằng mô hình có performance tốt nhưng proxy signal cũng mạnh hơn. Vì vậy, nếu chọn XGBoost + ROC làm mô hình chính, cần đi kèm giám sát fairness định kỳ và kiểm tra drift của các proxy attribute như `credit_amount`, `age`, `checking_status`. Đối với Logistic Regression + ROC, proxy signal thấp hơn và mô hình dễ giải thích hơn, phù hợp làm phương án minh bạch hoặc benchmark kiểm toán.

# Chương 9

# Kết luận và hướng phát triển

## 9.1 Kết luận chính

Project đã xây dựng và đánh giá pipeline fairness in credit scoring trên bộ dữ liệu German Credit với protected attribute là gender. Kết quả thực nghiệm dẫn đến bốn kết luận chính.

Thứ nhất, mô hình có gender trực tiếp tạo fairness gap lớn hơn. Cả ba họ mô hình khi thêm gender đều có SPD âm đáng kể, nghĩa là female có approval rate thấp hơn male. Logistic Regression + gender là trường hợp lệch rõ nhất với SPD -0.107 và AOD -0.098.

Thứ hai, bỏ gender khỏi feature matrix là cần thiết nhưng chưa đủ. Các baseline không có gender cải thiện SPD/AOD so với nhóm có gender, nhưng vẫn còn chênh lệch. Điều này phù hợp với phân tích proxy: nhiều attribute còn lại vẫn chứa tín hiệu gender gián tiếp.

Thứ ba, Reweighing giúp cải thiện fairness trong một số trường hợp nhưng mức cải thiện không ổn định. Logistic Regression + RW giảm AOD đáng kể, nhưng XGBoost + RW không cải thiện so với XGBoost baseline. Vì vậy, Reweighing phù hợp như một bước can thiệp nhẹ, nhưng chưa phải phương pháp tốt nhất trong bộ thí nghiệm này.

Thứ tư, Reject Option Classification tạo trade-off tốt nhất. Logistic Regression + ROC đưa AOD gần về 0 và giảm SPD còn -0.020. XGBoost + ROC đạt AUC và Balanced Accuracy cao nhất trong nhóm được chọn, đồng thời giữ AOD ở mức thấp. Vì vậy, hai mô hình cuối cùng được đề xuất là:

- **XGBoost + ROC**: lựa chọn chính khi ưu tiên performance.
- **Logistic Regression + ROC**: lựa chọn khi ưu tiên diễn giải và fairness ổn định.

## 9.2 Khuyến nghị sử dụng

Nếu triển khai trong bối cảnh cần ra quyết định tự động, XGBoost + ROC nên được đi kèm cơ chế monitoring. Các metric cần theo dõi gồm AUC, Balanced Accuracy, SPD, AOD, approval rate theo gender và TPR/FPR theo gender. Nếu phân phối dữ liệu thay đổi, threshold và reject margin cần được hiệu chỉnh lại trên dữ liệu validation mới.

Nếu hệ thống cần giải thích cho hội đồng, auditor hoặc người dùng cuối, Logistic Regression + ROC là phương án an toàn hơn. Mặc dù AUC thấp hơn XGBoost + ROC, mô hình tuyến tính dễ phân tích hơn và AOD gần bằng 0 trong kết quả OOF.

## 9.3 Hạn chế

Bộ dữ liệu chỉ có 1.000 mẫu, nên độ lệch chuẩn giữa các fold không nhỏ. Một số metric fairness theo nhóm có thể nhạy với số lượng mẫu trong từng giao điểm gender/label. Ngoài ra, gender trong German Credit được suy ra từ một thuộc tính kết hợp personal status and sex; cách ánh xạ nhị phân male/female là cần thiết cho project nhưng vẫn đơn giản hóa thực tế xã hội.

Proxy analysis trong báo cáo dùng SHAP và mô hình phụ dự đoán gender. Cách làm này phát hiện tương quan dự đoán, không chứng minh quan hệ nhân quả. Do đó, các attribute có proxy-risk cao nên được xem là tín hiệu cần kiểm tra kỹ, không phải kết luận rằng feature đó phải bị loại bỏ trong mọi bối cảnh.

## 9.4 Hướng phát triển

Các hướng phát triển tiếp theo gồm:

- Thử nghiệm thêm threshold optimization đa mục tiêu, ví dụ tối ưu AUC hoặc Balanced Accuracy với ràng buộc SPD/AOD cụ thể.
- Bổ sung confidence interval bằng bootstrap cho các fairness metrics.
- Phân tích intersectional fairness nếu dữ liệu có thêm thuộc tính nhạy cảm khác như tuổi hoặc tình trạng hôn nhân.
- So sánh thêm các phương pháp causal fairness để phân biệt proxy hợp lý và proxy có nguy cơ phân biệt đối xử.
- Tạo dashboard monitoring để theo dõi fairness drift sau triển khai.

Tóm lại, kết quả của project cho thấy fairness trong credit scoring là một bài toán trade-off thực sự. Mô hình tốt không chỉ cần dự đoán chính xác, mà còn cần được kiểm tra theo nhóm, phân tích proxy và hiệu chỉnh hậu xử lý khi cần.

# Tài liệu tham khảo


Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.

Moritz Hardt, Eric Price, and Nati Srebro. Equality of opportunity in supervised learning. In *Advances in Neural Information Processing Systems*, 2016.

Hans Hofmann. Statlog (german credit data) data set. UCI Machine Learning Repository, 1994. Accessed for academic experimentation.

Faisal Kamiran and Toon Calders. Data preprocessing techniques for classification without discrimination. In *Knowledge and Information Systems*, 2012.

Faisal Kamiran, Asim Karim, and Xiangliang Zhang. Decision theory for discrimination-aware classification. In *IEEE International Conference on Data Mining*, 2012.

Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, 2017.

Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: Unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, 2018.