Lab Bài 2: Responsible AI & AI Risk Assessment

Brief ngắn để sinh notebook/handout Google Colab

Lab handout – 1,5 giờ

Mục tiêu Lab

- Áp dụng khung Responsible AI vào một use case cụ thể.
- Phân loại dữ liệu và xếp use case theo mức rủi ro (tinh thần EU AI Act).
- Lập **AI Risk Assessment** theo 5 nhóm: accuracy/hallucination, bias, privacy, security, accountability.
- Đề xuất guardrail, mức tự động hóa (Assist/Approve/Automate) và điểm human control.
- Chốt quyết định **go / pilot / not yet** kèm lý do.

Bối cảnh Lab

Yêu cầu chung

Mỗi nhóm chọn một use case AI (có thể dùng lại use case nhóm quan tâm) và đánh giá trách nhiệm & rủi ro trước khi đề xuất triển khai.

- Không cần triển khai model thật; trọng tâm là tư duy kiểm soát rủi ro.
- Notebook/handout chủ yếu là markdown và bảng để nhóm điền.

Use case gợi ý

- Trợ lý RAG hỏi đáp sổ tay vận hành.
- Phân loại alarm/ticket để hỗ trợ routing.
- Phân tích phản hồi khách hàng (sentiment/chủ đề).
- Object detection giám sát hạ tầng từ camera.
- Incident assistant agent có tool KPI và knowledge search.

Phần 1 – Phân loại dữ liệu

Với use case đã chọn, liệt kê các loại dữ liệu đầu vào và phân loại:

- **Public** / **Internal** / **Confidential** / **Restricted**.
- Có dữ liệu cá nhân (tên, SĐT, email, định danh KH) không?
- Dữ liệu nào cần masking/redaction trước khi đưa vào AI?
- Theo quy định Tập đoàn và pháp luật VN (Nghị định 13/2023, Luật ANM), có cần đồng ý/đánh giá tác động không?

Phần 2 – Xếp mức rủi ro (EU AI Act)

- Use case thuộc mức nào: unacceptable / high / limited / minimal?
- Nếu high-risk: cần tài liệu, giám sát con người và minh bạch gì?
- Nếu limited: nghĩa vụ minh bạch (báo người dùng đang tương tác với AI) là gì?
- Ghi lý do xếp mức.

Phần 3 – AI Risk Assessment (5 nhóm)

Nhóm	Rủi ro cụ thể trong use case	Biện pháp kiểm soát
Accuracy/Hallucination		
Fairness/Bias		
Privacy		
Security		
Accountability		

- Mỗi nhóm nêu ít nhất 1 rủi ro và 1 biện pháp cụ thể (metric, guardrail, quy trình).

Phần 4 – Explainability & Bias

- Nếu model là classifier NLP/CV: giải thích bằng gì (SHAP/LIME, feature/từ/vùng ảnh quan trọng)?
- Nếu là LLM/RAG: giải thích bằng grounding + citation.
- Bias: nhóm dữ liệu nào (site nhỏ, khu vực xa, thiết bị cũ, ban đêm...) dễ bị đánh giá sai?
- Đo lỗi theo nhóm như thế nào để phát hiện bias?

Phần 5 – AI Use-case Canvas

Mục	**Câu hỏi cần trả lời**
Problem	Pain point nghiệp vụ là gì?
User	Ai sử dụng kết quả AI? Ai chịu ảnh hưởng?
Data	Dữ liệu nào? Phân loại & quyền?
AI task	Classification, extraction, RAG, CV, agent?
Output	Đầu ra dùng được là gì?
Metric	Đo thành công & bias bằng gì?
Risk	Sai thì hậu quả gì? Guardrail?
Human control	Người duyệt ở bước nào? Assist/Approve/Automate?

Phần 6 – Quyết định triển khai

Go	Pilot	Not yet
Rủi ro thấp, metric đạt, dữ liệu ổn, guardrail rõ, hợp quy định.	Có giá trị nhưng cần thử phạm vi hẹp, người giám sát chặt.	Dữ liệu thiếu, rủi ro cao, chưa có owner, chưa rõ pháp lý.

Prompt tạo notebook/handout sau này

Yêu cầu

Tạo notebook/handout Google Colab cho Lab Responsible AI & Risk Assessment. Không cần gọi model thật; có các cell markdown và bảng để nhóm điền: phân loại dữ liệu, mức rủi ro EU AI Act, risk assessment 5 nhóm, ghi chú XAI & bias, AI Use-case Canvas và quyết định go/pilot/not yet.

- Có dữ liệu mẫu nhỏ cho 3 use case: RAG, NLP ticket/feedback, Agent incident.
- Có template bảng risk assessment và peer review.
- Xuất kết quả cuối thành markdown summary.

Deliverable cuối Lab

- Bảng phân loại dữ liệu và mức rủi ro.
- Bảng AI Risk Assessment 5 nhóm (rủi ro + biện pháp).
- Ghi chú XAI (SHAP/LIME hoặc grounding) và phân tích bias theo nhóm.
- AI Use-case Canvas hoàn chỉnh.
- Quyết định go / pilot / not yet kèm lý do.

Câu hỏi debrief bắt buộc

1. Use case này có thể sai hoặc gây bất công cho nhóm nào?
2. Dữ liệu nào bị cấm/cần masking theo quy định Tập đoàn và pháp luật VN?
3. Làm sao giải thích quyết định của model cho người dùng/kiểm toán?
4. Ai chịu trách nhiệm cuối cùng và con người kiểm soát ở bước nào?