AI Engineer – Module 3

Lab Bài 3: Prompt Challenge – Phân loại ticket & gọi model qua adapter

Google Colab – 1,5 giờ

Lab độc lập với lecture. Mục tiêu là **so sánh prompt bằng test set**, không chọn prompt theo cảm giác.

1. Mục tiêu và deliverable

Mục tiêu:

- Chạy baseline zero-shot trên 20–30 ticket/incident.
- Cải tiến prompt theo Role–Task–Context–Constraints–Output; thêm few-shot và structured JSON.
- Gọi model qua **adapter**: API LLM nội bộ (Viettel AI Platform) hoặc model từ Hugging Face Hub / cache fallback.
- Ghi accuracy/tỷ lệ đúng, JSON parse rate và lỗi còn lại.

Deliverable:

- Prompt template phiên bản cuối;
- bảng so sánh V1/V2/V3/V4;
- error table;
- giải thích vì sao chọn prompt cuối.

2. Blueprint notebook

Notebook nên có 7 phần:

1. **Business Context**: auto-route ticket cho nhóm NOC.
2. **Dataset**: 20–30 ticket tiếng Việt mô phỏng + ground truth label.
3. **Model Adapter**: hàm gọi LLM thống nhất – API nội bộ, model HF, hoặc response cache fallback.
4. **Prompt Versions**: V1, V2, V3, V4.
5. **Batch Run**: chạy toàn bộ test set cho từng version.
6. **Evaluation**: accuracy/tỷ lệ đúng, parse rate, error category.
7. **Reflection**: chọn prompt cuối và nêu giới hạn.

3. Model Adapter – gọi model an toàn

- Một hàm `call_model(messages, params)` che giấu backend.
- Backend 1: **API LLM nội bộ (Viettel AI Platform)** – endpoint + API key lấy từ environment/secret, **không hard-code**.
- Backend 2: **model từ Hugging Face Hub** chạy local (transformers pipeline), có thể dùng GPU.
- Backend 3: **response cache** để lab chạy được khi không có API/GPU.

An toàn dữ liệu

Dataset mô phỏng/ẩn danh; không gửi dữ liệu nhạy cảm tới endpoint chưa được phê duyệt (Bài 2).

4. Dữ liệu và nhãn

Dataset gợi ý: 20–30 mẫu, mỗi mẫu gồm:

- `ticket_id`;
- `text`;
- `true_label`;
- `notes` tùy chọn: case rõ, case mơ hồ, case thiếu dữ liệu.

Bộ nhãn tối thiểu:

Connectivity / Performance / Hardware / Configuration / Other

Yêu cầu

Có ít nhất 3–5 mẫu mơ hồ hoặc thiếu dữ liệu để kiểm tra `needs_review`.

5. Bốn phiên bản prompt

- **V1 – Baseline zero-shot**: "Phân loại ticket sau vào một nhóm sự cố: [ticket]."
- **V2 – Role/Task/Context/Constraints**: trợ lý phân luồng, chọn đúng một nhãn, định nghĩa nhãn, không tạo nhãn mới.
- **V3 – Few-shot**: 3–5 ví dụ input–output, phủ nhãn dễ nhầm, có case `needs_review`.
- **V4 – Structured JSON**: `{label, confidence, evidence, needs_review}`, không viết ngoài JSON.

Mỗi version chạy trên toàn bộ dataset; ghi output thô và normalize label nếu cần.

6. Validation cho V4

- JSON parse được;
- `label` thuộc allowed values;
- `evidence` không rỗng nếu confidence cao;
- `needs_review=true` khi thiếu dữ liệu hoặc confidence thấp.

System prompting

Đặt vai trò, chính sách và format vào system message; không để nội dung ticket phá vỡ chính sách (prompt injection).

7. Bảng so sánh prompt

Metric	V1	V2	V3	V4
Accuracy / correct rate				
JSON parse rate	–	–	–	
Label outside list				
Needs review				
useful				
Latency/token cost note				

Chọn prompt cuối: không nhất thiết là prompt accuracy cao nhất nếu rủi ro cao hơn.

8. Error table

Mỗi nhóm ghi ít nhất 5 lỗi đáng chú ý:

ID	Ticket tóm tắt	True / Pred	Loại lỗi	Cách sửa
			Sai nhãn / format / hallucination / thiếu review	

Mục tiêu

Biết lỗi còn lại là gì để quyết định tiếp tục prompt, thêm dữ liệu, chuyển RAG/fine-tuning/tool hay giữ human review.

9. Debrief bắt buộc

Trả lời ngắn trong notebook:

1. Prompt version nào tốt nhất và vì sao?
2. Lỗi còn lại thuộc nhóm nào?
3. Nếu triển khai thật, hậu quả false positive / false negative là gì?
4. Ticket nào cần human review?
5. Nên gọi API nội bộ hay model local từ Hub cho use case này? Vì sao?

10. Đặc tả để sinh notebook sau này

Prompt sinh notebook `.ipynb` cần yêu cầu:

- chạy được trên Google Colab;
- dataset mô phỏng 20–30 ticket tiếng Việt có ground truth;
- **adapter** gọi model: API nội bộ (key từ secret) / model HF (có thể GPU) / cache fallback; không hard-code credential;
- định nghĩa 4 prompt version V1–V4 với system prompt;
- batch inference cho từng prompt; parser/validator JSON cho V4;
- tính accuracy, parse rate, lỗi nhãn ngoài danh sách;
- tạo bảng comparison và error table;
- markdown reflection ở cuối notebook.