# Lab Bài 5: Semantic Search & Vector DB trên sổ tay kỹ thuật

Brief ngắn để sinh notebook Google Colab

Lab handout – 1,5 giờ

# Mục tiêu Lab

Học viên tạo được một notebook semantic search tối giản:

- đọc tập tài liệu/sổ tay kỹ thuật mẫu,
- chia tài liệu thành chunk (ingestion $\rightarrow$ chunking),
- tạo embedding và index bằng **FAISS hoặc Chroma**,
- truy vấn top-k chunk,
- so sánh keyword search và semantic search,
- ghi lại failure case và nguyên nhân.

# Input cần chuẩn bị cho notebook

- 10–30 đoạn tài liệu/sổ tay ngắn bằng tiếng Việt.
- Chủ đề nên thống nhất: vận hành mạng, xử lý alarm, kiểm tra site, quy trình escalation.
- Mỗi tài liệu có metadata: `doc_id`, `title`, `version`, `category`.
- Dữ liệu mô phỏng, không chứa thông tin nhạy cảm.

# Cấu trúc notebook đề xuất

1. Business context.
2. Load sample documents (ingestion).
3. Chunking function (chunk_size, overlap).
4. Embedding model/API setup (vd: sentence-transformers từ HF Hub).
5. Build vector index (FAISS/Chroma).
6. Semantic search function.
7. Keyword baseline.
8. Evaluation table.
9. Error analysis và reflection.

# Phần 1 – Business Context

## Bối cảnh

Kỹ thuật viên cần tìm nhanh hướng xử lý từ sổ tay vận hành. Người dùng thường hỏi bằng ngôn ngữ tự nhiên, không nhớ chính xác tên tài liệu hoặc từ khóa.

## Quyết định cần hỗ trợ

Tìm đúng đoạn tài liệu liên quan để chuẩn bị cho bước hỏi đáp RAG ở Bài 6.

# Phần 2 – Chunking

Yêu cầu notebook:

- Có hàm chia văn bản thành chunk theo độ dài ký tự hoặc token gần đúng.
- Có tham số `chunk_size` và `overlap` để học viên thay đổi.
- Lưu lại metadata gốc cho từng chunk.
- In ra 3 chunk mẫu để học viên đọc và nhận xét.

# Phần 3 – Embedding và Vector Index

Notebook có thể dùng một trong hai hướng:

- **sentence-transformers + FAISS/Chroma**: chạy local trên Colab (có thể dùng GPU).
- **Embedding API**: nếu đơn vị đào tạo cấp quyền truy cập.

Yêu cầu: code khung nên chuẩn bị sẵn 70–80%, học viên chủ yếu thay tham số, query và cách đánh giá.

## Ghi chú Vector DB

FAISS: thư viện ANN nhanh, tự quản index. Chroma: vector DB nhẹ, có metadata filter + persistence. (Milvus cho quy mô lớn – không bắt buộc trong lab.)

# Phần 4 – Semantic Search

Hàm search cần nhận:

- query tiếng Việt,
- tham số `top_k`,
- tùy chọn filter metadata đơn giản (vd: version).

Kết quả trả về bảng gồm: rank, score, title, version, chunk text.

# Phần 5 – Keyword Baseline

Thêm baseline đơn giản để so sánh:

- search theo từ khóa xuất hiện trong chunk,
- hoặc BM25 nếu muốn nâng cấp nhẹ,
- dùng cùng bộ query với semantic search.

Mục tiêu không phải tối ưu search engine, mà để thấy trade-off keyword vs semantic.

# Bộ query kiểm thử

Chuẩn bị tối thiểu 5 query:

1. Query chứa mã lỗi/site ID chính xác.
2. Query diễn đạt gần nghĩa nhưng không trùng từ khóa.
3. Query hỏi theo tình huống vận hành.
4. Query cần đúng phiên bản tài liệu.
5. Query ngoài phạm vi tài liệu để kiểm tra “không tìm thấy”.

# Bảng đánh giá trong notebook

| Query | Keyword result | Semantic result | Nhận xét lỗi | Cách cải thiện |
|---|---|---|---|---|
| Q1 | | | | |
| Q2 | | | | |
| Q3 | | | | |
| Q4 | | | | |
| Q5 | | | | |

# Thử nghiệm bắt buộc

Học viên cần chạy ít nhất 3 thử nghiệm:

- Thay `chunk_size`: nhỏ hơn và lớn hơn.
- Thay `top_k`: ví dụ 1, 3, 5.
- So sánh keyword search với semantic search trên cùng query.

Ghi lại ít nhất 2 failure case.

# Deliverable cuối Lab

Nộp hoặc lưu lại:

- Notebook chạy được end-to-end.
- 5 query kiểm thử và kết quả top-k.
- Bảng so sánh keyword/semantic search.
- Ít nhất 2 failure case và nguyên nhân.
- Đề xuất cải thiện trước khi chuyển sang RAG ở Bài 6.

# Debrief cuối Lab

Trả lời ngắn trong notebook:

1. Search thất bại ở query nào? Vì sao?
2. Lỗi do tài liệu, chunking, embedding, query hay top-k?
3. Khi nào keyword tốt hơn semantic?
4. Chọn Vector DB nào cho use case thật (FAISS/Chroma/Milvus) và vì sao?
5. Nếu dùng kết quả này cho RAG, rủi ro nghiệp vụ là gì? Human review ở bước nào?