Lab Bài 7: Ticket Intelligence & Fine-tuning nhẹ (LoRA/QLoRA)

Brief ngắn để sinh notebook Google Colab

Lab handout – 1,5 giờ

Mục tiêu Lab

- Tạo notebook Ticket Intelligence cho dữ liệu ticket/alarm/feedback mô phỏng.
- Chạy baseline rule/keyword và model/LLM cho classification + extraction.
- Tạo confusion matrix hoặc bảng đúng/sai thủ công; đánh giá precision/recall.
- (Mở rộng) Fine-tune nhẹ một model open-source bằng **LoRA/QLoRA** trên GPU.
- Đề xuất mức tự động hóa: auto-route, assist hay manual review.

Input cần chuẩn bị

- 30–100 ticket/incident/feedback tiếng Việt mô phỏng, đã loại dữ liệu nhạy cảm.
- Mỗi dòng có `ticket_id`, `text`, nhãn ground truth và metadata tùy chọn.
- Bộ nhãn: Connectivity, Performance, Hardware, Configuration, Other/Need review.
- Schema extraction: site_id, symptom, severity, time_mentioned, suspected_cause, action_taken.
- Một vài mẫu mơ hồ, thiếu thông tin hoặc chứa nhiều vấn đề.

Cấu trúc notebook đề xuất

- 1. Business context và câu hỏi nghiệp vụ.
- 2. Load dataset ticket/alarm/feedback.
- 3. Khai báo label set và extraction schema.
- 4. Baseline rule/keyword.
- 5. Model/LLM classification.
- 6. Model/LLM extraction JSON.
- 7. (Mở rộng) Fine-tune LoRA/QLoRA.
- 8. Evaluation, error analysis và automation decision.

Business context

- Người dùng: điều phối viên vận hành, support level 1, hoặc đội CSKH.
- Pain point: đọc nhiều ticket/feedback thủ công, phân loại không nhất quán, route chậm.
- AI task: gợi ý nhãn, trích xuất thông tin chính, phân tích cảm xúc phản hồi.
- Không làm: tự động đóng ticket hoặc thay đổi cấu hình hệ thống.
- Mức an toàn mặc định: Assist trước, chỉ automate khi chất lượng đủ tốt.

Cell nhóm 1–3 – Baseline, Classification, Extraction

- **Rule/keyword**: dictionary + regex cho site_id/thời gian; chạy baseline toàn dataset.
- **Classification**: prompt/model chỉ chọn nhãn trong allowed labels; output JSON (label, confidence, reason, needs_review).
- **Extraction**: output JSON đúng schema; trường thiếu trả `null`/`unknown`; validate parse + allowed values; so sánh field chính với ground truth.

Cell nhóm 4 – (Mở rộng) Fine-tune LoRA/QLoRA

- Chuẩn bị dữ liệu train (text + label) từ chính dataset ticket đã gán nhãn.
- Nạp base model open-source (4-bit với QLoRA để tiết kiệm bộ nhớ GPU).
- Cấu hình LoRA adapter (r, alpha, target_modules, dropout) và train vài epoch.
- So sánh model fine-tuned với baseline prompt/rule trên cùng test set.

Lưu ý

Ưu tiên chạy trên GPU (`torch.cuda`). Đây là phần mở rộng; nhóm không có GPU có thể chỉ mô tả quy trình và dùng kết quả mẫu.

Khung code QLoRA (khái niệm)

pseudo-code: peft + transformers + bitsandbytes

```
import torch; assert torch.cuda.is_available()
from transformers import AutoModelForSequenceClassification, BitsAndBytesConfig
from peft import LoraConfig, get_peft_model
bnb = BitsAndBytesConfig(load_in_4bit=True, bnb_4bit_quant_type="nf4",
  bnb_4bit_compute_dtype=torch.bfloat16)
base = AutoModelForSequenceClassification.from_pretrained(MODEL,
  num_labels=5, quantization_config=bnb, device_map="cuda")
lora = LoraConfig(r=16, lora_alpha=32, lora_dropout=0.05, task_type="SEQ_CLS")
model = get_peft_model(base, lora)
# train với Trainer trên train set, đánh giá trên test set
```

Học viên tự chạy; không chạy trong lớp. Chi tiết tùy thư viện và model.

Cell nhóm 5 – Evaluation

- Tính accuracy tổng quan nếu có thể.
- Tạo confusion matrix hoặc bảng `true_label` vs `pred_label`.
- Tính precision, recall cho nhãn quan trọng; so sánh baseline vs fine-tuned.
- Tạo bảng lỗi: ticket_id, text ngắn, lỗi, nguyên nhân, hướng sửa.
- Không chấm chỉ dựa trên việc notebook chạy thành công.

Cell nhóm 6 – Automation decision

- Với từng nhãn hoặc loại ticket, chọn: auto-route, assist hoặc manual review.
- Confidence thấp hoặc nhãn rủi ro cao $\rightarrow$ human review.
- Nêu một false positive nguy hiểm và một false negative nguy hiểm.
- Đề xuất cải thiện: thêm rule, thêm metadata, sửa nhãn, thêm examples, hoặc fine-tune thêm dữ liệu.

Prompt sinh notebook sau này

- Tạo Google Colab notebook cho Lab Ticket Intelligence & Fine-tuning.
- Dataset ticket/feedback tiếng Việt mô phỏng, có label ground truth và schema extraction.
- Có rule baseline, LLM/model classification, JSON extraction, evaluation table và error analysis.
- Có phần mở rộng fine-tune LoRA/QLoRA (peft + transformers + bitsandbytes), ưu tiên GPU.
- Code khung 70–80%; không hard-code credential; có cache fallback nếu không gọi API/không có GPU.

Deliverable cuối Lab

- Notebook đã chạy được.
- Bảng kết quả classification và extraction.
- Confusion matrix hoặc bảng đúng/sai; so sánh baseline vs fine-tuned (nếu làm).
- Ít nhất 5 lỗi đã phân tích nguyên nhân.
- Quyết định mức tự động hóa: auto-route, assist hay manual review.

Debrief bắt buộc

- Model sai hoặc không chắc ở tình huống nào?
- False positive và false negative có hậu quả gì trong workflow thật?
- Fine-tuning (LoRA/QLoRA) có cải thiện đáng kể so với prompt/rule không? Có đáng chi phí không?
- Trường hợp nào phải bắt buộc human review?
- Nếu làm lại, cần thêm dữ liệu, nhãn hay guardrail nào?